同济大学
TONGJI UNIVERSITY

图像分析与机器学习

1 线性回归与最小二乘



张绍明



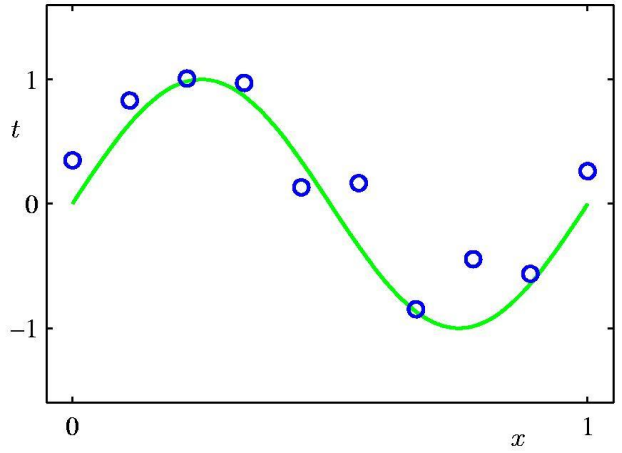
目录

同济大学
TONGJI UNIVERSITY

1. 最小二乘曲线拟合及其几何意义
2. 最小二乘曲线拟合的概率意义
3. 损失函数与最优化方法
4. 模型的泛化能力与正则化

1. 最小二乘曲线拟合及其几何意义

$$y(x, \mathbf{w}) = w_0 + w_1 x^1 + w_2 x^2, \ldots, + w_M x^M = \sum_{i=0}^{M} w_i x^i$$



变量约定

1. x 自变量：观测的时刻、空间位置等

2. t 观测值：观测到的变量的值

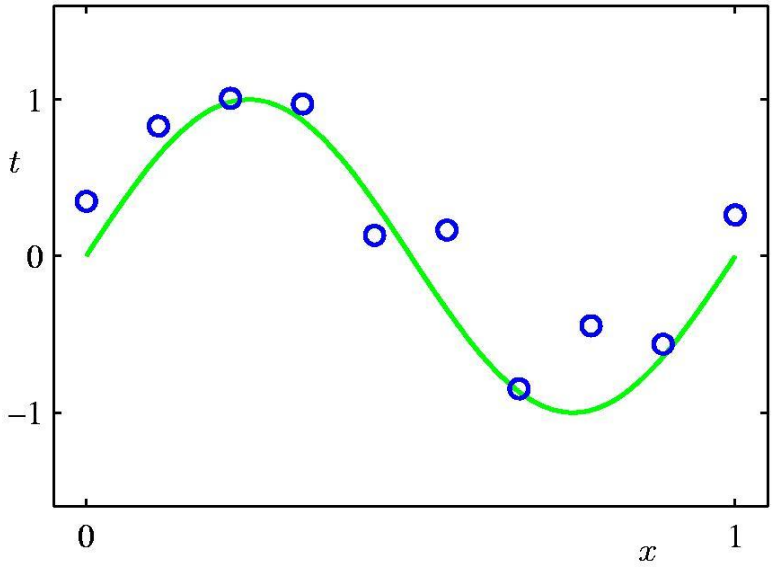
3. y 预测值：给定x，对真实值进行的预测结果，$y=f(x)$

典型的监督机器学习：根据一批观测数据（x, t），估计 f。

一、最小二乘曲线拟合

- 给定一组数据(x_n, t_n)，$n = 1,2,\dots,N$
- 如何估计x_n、t_n之间的关系，假设**用多项式模型** $y = \mathbf{w}^T\mathbf{x}$

$$y(x,\mathbf{w}) = w_0 + w_1x^1 + w_2x^2,\dots,+w_Mx^M = \sum_{i=0}^{M} w_ix^i$$



为什么用多项式，0阶、1阶、2阶…，哪个好?

$$\mathbf{x}_n = \begin{pmatrix} x_n^0 \\ x_n^1 \\ \vdots \\ x_n^M \end{pmatrix},\ \mathbf{t} = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{pmatrix},\ \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_M \end{pmatrix}$$

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{pmatrix},\ N \times (M+1)$$

一、最小二乘曲线拟合

- 给定一组数据(x_n, t_n)，$n = 1,2,\dots,N$
- 如何估计x_n、t_n之间的关系，假设**用多项式模型** $y = \mathbf{w}^T\mathbf{x}$

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \mathbf{X}\mathbf{w} \qquad \mathbf{t} = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{pmatrix}$$

模型预测值　　观测值

$$\mathbf{x}_n = \begin{pmatrix} x_n^0 \\ x_n^1 \\ \vdots \\ x_n^M \end{pmatrix}, \quad \mathbf{t} = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_M \end{pmatrix}$$

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{pmatrix}, \quad N \times (M+1)$$

★ 模型w如何评价?

- 预测值与观测值的差异（损失函数）
- 二范数（欧式距离）最小

$$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{X}\mathbf{w} - \mathbf{t}\|^2$$

- 令一阶导数为0（向量求导）

$$\frac{dLoss(\mathbf{w})}{d\mathbf{w}} = \mathbf{X}^T(\mathbf{X}\mathbf{w} - \mathbf{t}) = 0$$

- 得到最优解：$\mathbf{w} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{t}$

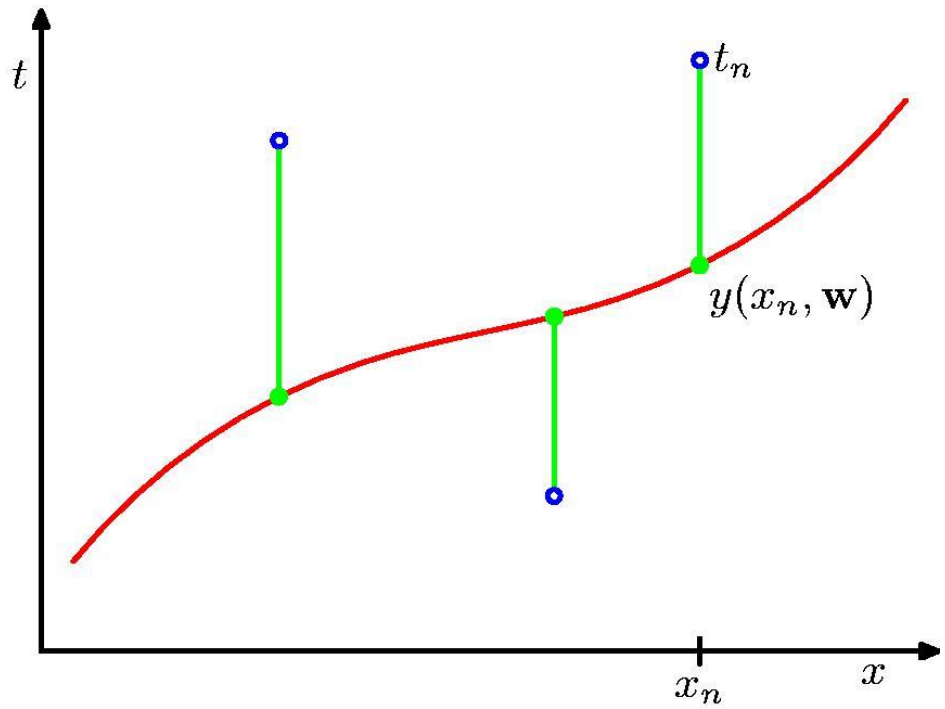
一、最小二乘曲线拟合

$\mathbf{X}^T\mathbf{X}\mathbf{w} - \mathbf{X}^T\mathbf{t} = \mathbf{0}$　最小二乘的法方程

$$\mathbf{w} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{t}$$

$$\mathbf{x}_n = \begin{pmatrix} x_n^0 \\ x_n^1 \\ \vdots \\ x_n^M \end{pmatrix}, \quad \mathbf{t} = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_N \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_M \end{pmatrix}$$

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{pmatrix}, \quad N \times (M+1)$$



一、最小二乘曲线拟合的几何意义

$$N \times (M+1) \qquad (M+1) \times 1 \qquad N \times 1$$

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{pmatrix} \qquad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_M \end{pmatrix} \qquad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \mathbf{X}\mathbf{w}$$

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{pmatrix} = \begin{pmatrix} w_0 x_1^0 + w_1 x_1^1 + \cdots + w_M x_1^M \\ w_0 x_2^0 + w_1 x_2^1 + \cdots + w_M x_2^M \\ \vdots \\ w_0 x_N^0 + w_1 x_N^1 + \cdots + w_M x_N^M \end{pmatrix} = w_0 \begin{pmatrix} x_1^0 \\ x_2^0 \\ \vdots \\ x_N^0 \end{pmatrix} + w_1 \begin{pmatrix} x_1^1 \\ x_2^1 \\ \vdots \\ x_N^1 \end{pmatrix} + \cdots + w_M \begin{pmatrix} x_1^M \\ x_2^M \\ \vdots \\ x_N^M \end{pmatrix}$$

一、最小二乘曲线拟合的几何意义

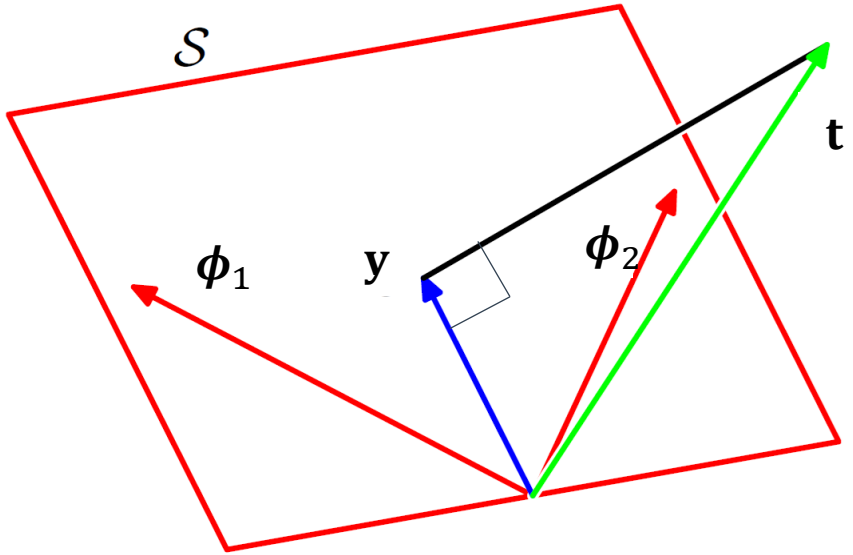
$$\mathbf{y}=\mathbf{Xw}=w_0\begin{pmatrix}x_1^0\\x_2^0\\\vdots\\x_N^0\end{pmatrix}+w_1\begin{pmatrix}x_1^1\\x_2^1\\\vdots\\x_N^1\end{pmatrix}+\cdots+w_M\begin{pmatrix}x_1^M\\x_2^M\\\vdots\\x_N^M\end{pmatrix}$$

特征，基函数

令$\boldsymbol{\phi}_i(x_1,x_2,\ldots,x_N)=\begin{pmatrix}x_1^i\\x_2^i\\\vdots\\x_N^i\end{pmatrix}$，有：$\mathbf{y}=\sum_{i=0}^{M}w_i\boldsymbol{\phi}_i$

回想傅里叶变换课程中对于向量及其存在的空间的讲解，一个是空间的基按列构成的矩阵，一个是系数。

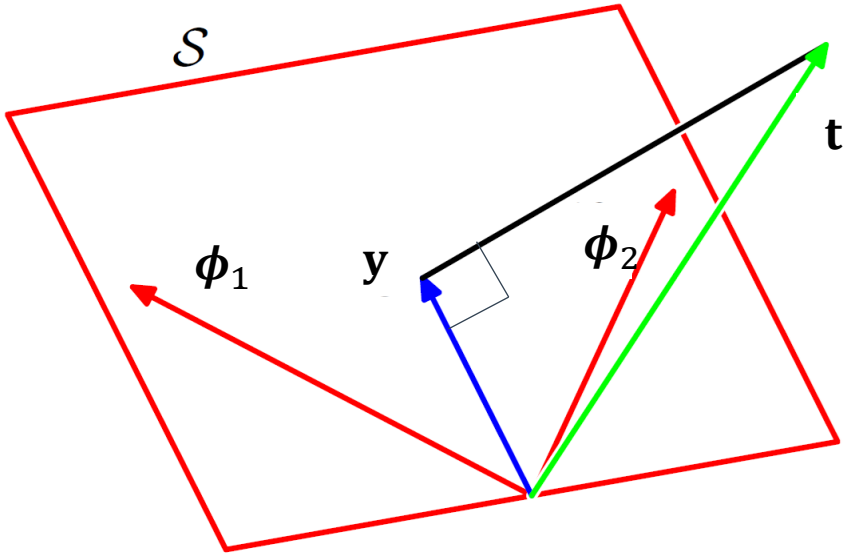
1. 当M+1<N 时，$\{\boldsymbol{\phi}_i, i=0,1,\ldots,M\}$张成了N维空间的M+1维子空间
2. 子空间中的每个向量**y**都可用$\{\boldsymbol{\phi}_i\}$的线性组合来表达
3. 即$\{\boldsymbol{\phi}_i\}$构成M+1维子空间的基，完备但不一定正交
   - $\{\boldsymbol{\phi}_i\}$可由子空间的归一化完备正交基的线性组合表示
   - 其他向量可由$\{\boldsymbol{\phi}_i\}$的线性组合间接表示



机器学习训练样本个数一般远大于模型参数，数据丰富度高于模型复杂度。小样本学习例外。

一、最小二乘曲线拟合的几何意义

1. 最小二乘解使得到**t**到**y**的欧式距离$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{y} - \mathbf{t}\|^2$最小
2. 而**y**位于$\{\boldsymbol{\phi}_i\}$张成的M+1维子空间中
3. LS相当于在M+1维子空间中找到距离**t**最近的点$\mathbf{y} = \sum_{i=0}^{M} w_i \boldsymbol{\phi}_i$
4. **N=3, M+1=2时，子空间为三维空间中的平面**
5. **此时，最小二乘相当于找到向量t在平面的投影**$\mathbf{y} = \sum_{i=0}^{M} w_i \boldsymbol{\phi}_i$



$$\boldsymbol{\phi}_i(x_1, x_2, \dots, x_N) = \begin{pmatrix} x_1^i \\ x_2^i \\ \vdots \\ x_N^i \end{pmatrix} \qquad \mathbf{y} = \sum_{i=0}^{M} w_i \boldsymbol{\phi}_i = \mathbf{X}\mathbf{w} = w_0 \begin{pmatrix} x_1^0 \\ x_2^0 \\ \vdots \\ x_N^0 \end{pmatrix} + w_1 \begin{pmatrix} x_1^1 \\ x_2^1 \\ \vdots \\ x_N^1 \end{pmatrix} + \cdots + w_M \begin{pmatrix} x_1^M \\ x_2^M \\ \vdots \\ x_N^M \end{pmatrix}$$

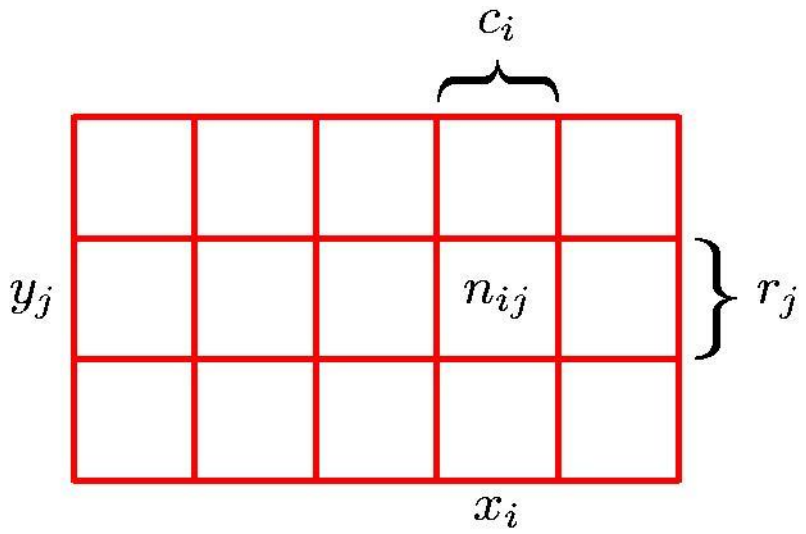
2 最小二乘曲线拟合的概率意义

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

经典机器学习常用的概率基础知识

1. 边缘概率、联合概率、条件概率
2. 和规则、积规则
3. 贝叶斯定理
4. 概率密度
5. 期望：条件期望、逼近期望
6. 方差与协方差
7. 正态分布、多变量正态分布
8. 极大似然估计、最大后验概率估计

二、最小二乘曲线拟合的概率意义-基础概率知识回顾



联合概率

$$p(X = x_i, Y = y_j) = \frac{n_{ij}}{N}$$

边缘概率

$$p(X = x_i) = \frac{c_i}{N}.$$

条件概率

$$p(Y = y_j | X = x_i) = \frac{n_{ij}}{c_i}$$

求和规则 $$p(X) = \sum_Y p(X, Y)$$

乘积规则 $$p(X, Y) = p(Y|X)p(X)$$

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

贝叶斯定理

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$$p(X) = \sum_Y p(X,Y) \qquad p(X) = \sum_Y p(X|Y)p(Y)$$

$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$

似然度　　先验概率

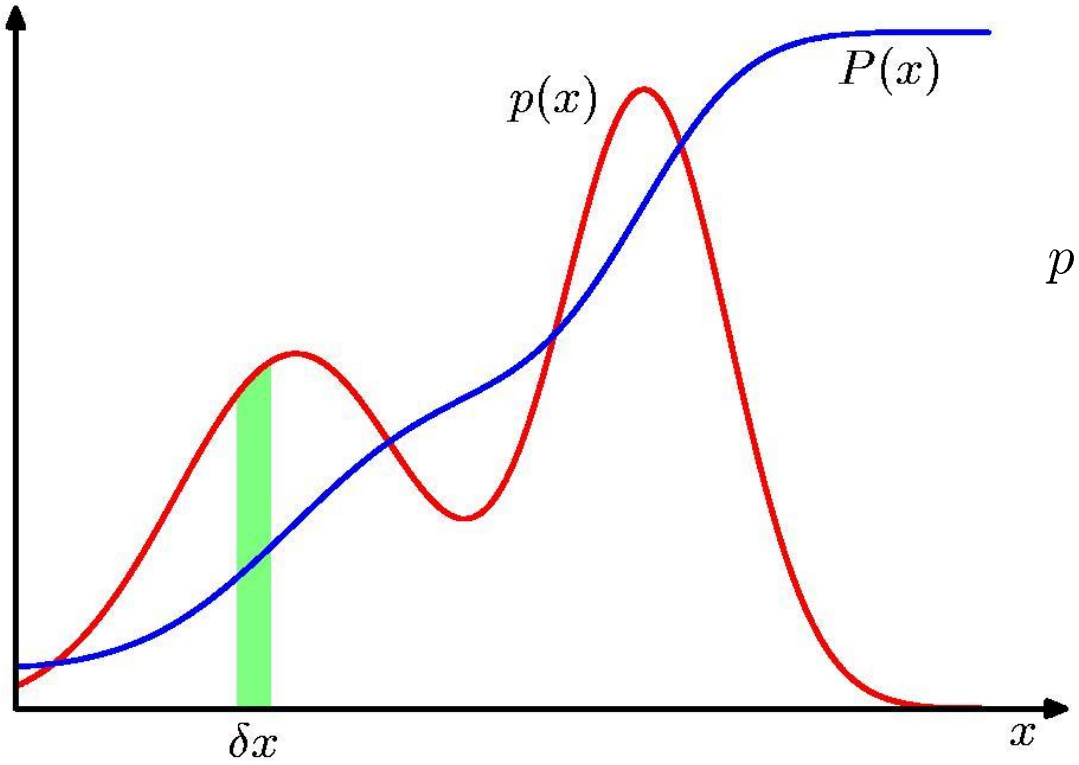
后验概率：似然度乘先验假设

例1：2人打猎，有猎物被打中，判断是谁开的枪

例2：红绿出租车，有出租车拒载，判断是红还是绿

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

连续变量的概率密度函数(PDF)



$$p(x \in (a,b)) = \int_a^b p(x)\,\mathrm{d}x$$

$$P(z) = \int_{-\infty}^{z} p(x)\,\mathrm{d}x$$

$$p(x) \geqslant 0 \qquad \int_{-\infty}^{\infty} p(x)\,\mathrm{d}x = 1$$

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

期望 $\mathbb{E}[f] = \sum_x p(x) f(x)$

$$\mathbb{E}[f] = \int p(x) f(x) \, \mathrm{d}x$$

条件期望 $\mathbb{E}_x[f|y] = \sum_x p(x|y) f(x)$

Conditional Expectation
(discrete)

期望的逼近 $\mathbb{E}[f] \simeq \frac{1}{N} \sum_{n=1}^{N} f(x_n)$

Approximate Expectation
(discrete and continuous)

方差与协方差

$$\mathrm{var}[f] = \mathbb{E}\left[(f(x) - \mathbb{E}[f(x)])^2\right] = \mathbb{E}[f(x)^2] - \mathbb{E}[f(x)]^2$$

$$\begin{aligned}\mathrm{cov}[x, y] &= \mathbb{E}_{x,y}\left[\{x - \mathbb{E}[x]\}\{y - \mathbb{E}[y]\}\right] \\ &= \mathbb{E}_{x,y}[xy] - \mathbb{E}[x]\mathbb{E}[y]\end{aligned}$$

$$\begin{aligned}\mathrm{cov}[\mathbf{x}, \mathbf{y}] &= \mathbb{E}_{\mathbf{x},\mathbf{y}}\left[\{\mathbf{x} - \mathbb{E}[\mathbf{x}]\}\{\mathbf{y}^{\mathrm{T}} - \mathbb{E}[\mathbf{y}^{\mathrm{T}}]\}\right] \\ &= \mathbb{E}_{\mathbf{x},\mathbf{y}}[\mathbf{x}\mathbf{y}^{\mathrm{T}}] - \mathbb{E}[\mathbf{x}]\mathbb{E}[\mathbf{y}^{\mathrm{T}}]\end{aligned}$$

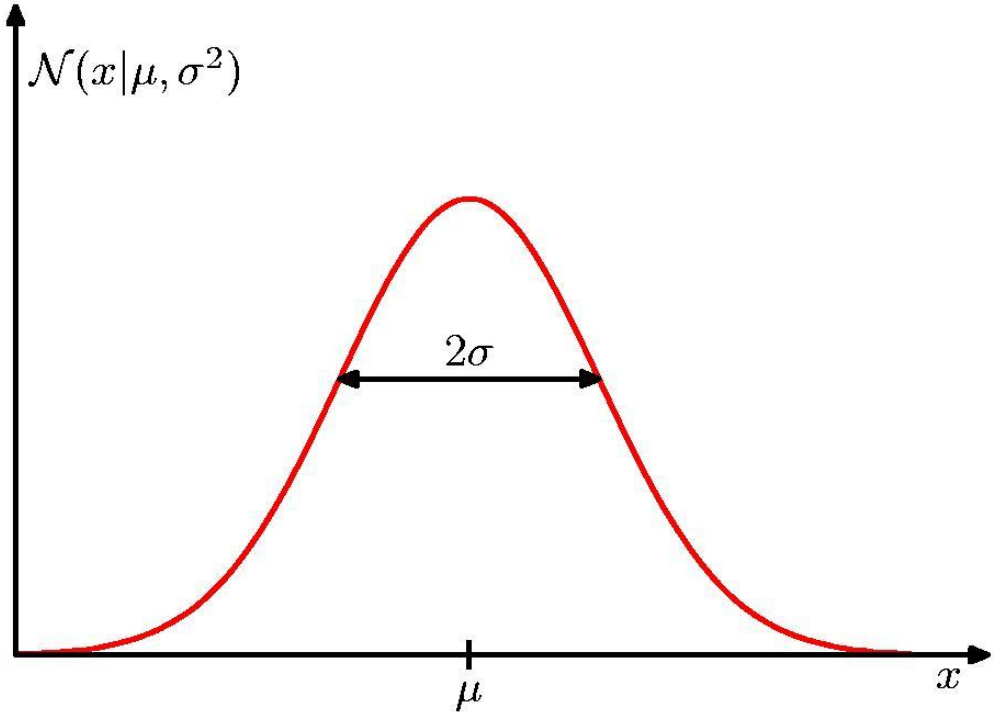
二、最小二乘曲线拟合的概率意义-基础概率知识回顾

正态分布

$$\mathcal{N}\left(x|\mu,\sigma^2\right)=\frac{1}{(2\pi\sigma^2)^{1/2}}\exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}$$

$$\mathcal{N}(x|\mu,\sigma^2)>0$$

$$\int_{-\infty}^{\infty}\mathcal{N}\left(x|\mu,\sigma^2\right)\,\mathrm{d}x=1$$



$$\mathbb{E}[x]=\int_{-\infty}^{\infty}\mathcal{N}\left(x|\mu,\sigma^2\right)x\,\mathrm{d}x=\mu$$

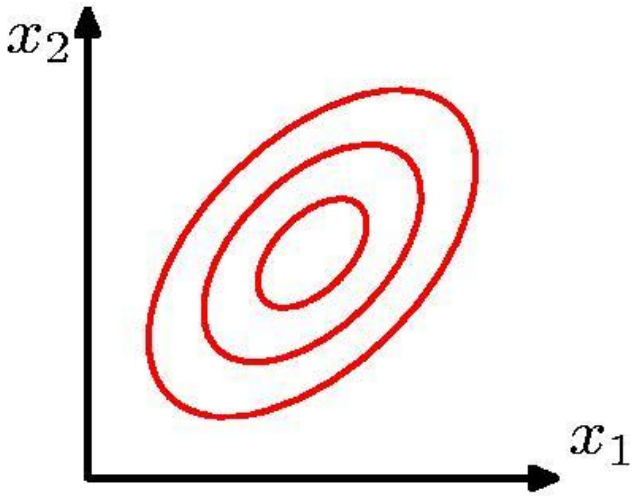
$$\mathbb{E}[x^2]=\int_{-\infty}^{\infty}\mathcal{N}\left(x|\mu,\sigma^2\right)x^2\,\mathrm{d}x=\mu^2+\sigma^2$$

$$\mathrm{var}[x]=\mathbb{E}[x^2]-\mathbb{E}[x]^2=\sigma^2$$

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

多变量正态分布

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu},\boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}}\frac{1}{|\boldsymbol{\Sigma}|^{1/2}}\exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^{\mathrm{T}}\boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right\}$$



协方差矩阵：

1. 由多维随机变量各个维度间的协方差构成
2. 对称矩阵

$$\boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{cov}(x_1,x_1) & \boldsymbol{cov}(x_1,x_2) \\ \boldsymbol{cov}(x_2,x_1) & \boldsymbol{cov}(x_2,x_2) \end{bmatrix}$$

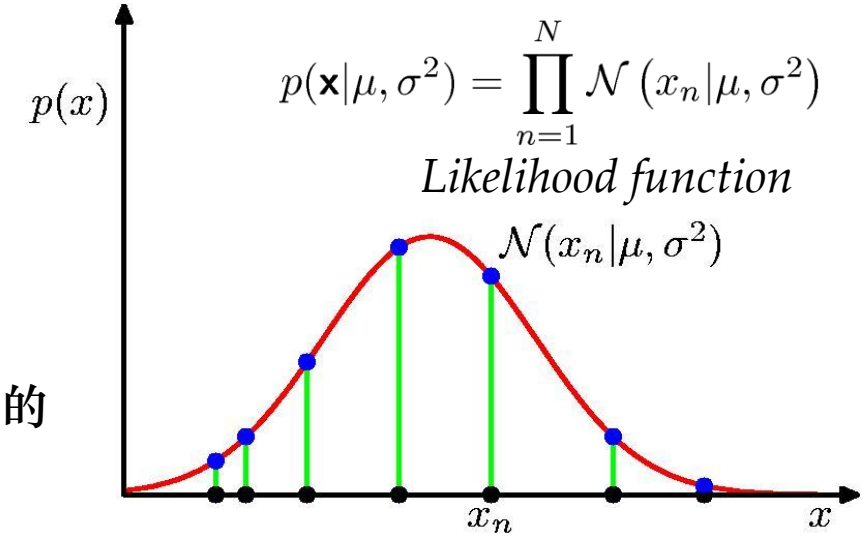
$$= \begin{bmatrix} \sigma^2(x_1) & \boldsymbol{E}[(x_1-\mu_1)(x_2-\mu_2)] \\ \boldsymbol{E}[(x_2-\mu_2)(x_1-\mu_1)] & \sigma^2(x_2) \end{bmatrix}$$

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

- 随机变量x服从正态分布

$$\mathcal{N}\left(x|\mu,\sigma^2\right)=\frac{1}{(2\pi\sigma^2)^{1/2}}\exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}$$

- 对该变量独立观测N次，获得N个观测值$(x_1,x_2,\cdots,x_N)$
- 各观测值$x_1,x_1,\cdots,x_N$，在给定参数μ,σ^2的条件下，是独立同分布的
  - 记作：i.i.d. independent and identically distributed



- 各观测值在给定参数μ,σ^2的条件下的联合概率：$p(x_1,x_2,\cdots,x_N|\mu,\sigma^2)=\prod_{n=1}^{N}\mathcal{N}(x_n|\mu,\sigma^2)$
  - 记 $\mathbf{x}=(x_1,x_2,\cdots,x_N)^T=\begin{pmatrix}x_1\\x_2\\\vdots\\x_N\end{pmatrix}$

该条件联合概率称为似然函数Likelihood Function

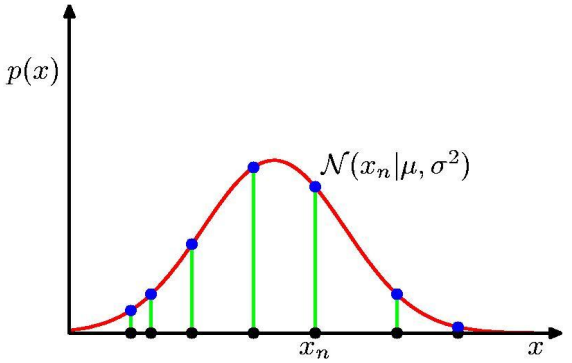
- 各观测值在给定参数μ,σ^2的条件下的联合概率为：$p(\mathbf{x}|\mu,\sigma^2)=\prod_{n=1}^{N}\mathcal{N}(x_n|\mu,\sigma^2)$

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

$$\mathcal{N}\left(x|\mu,\sigma^2\right)=\frac{1}{(2\pi\sigma^2)^{1/2}}\exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}$$

- 各观测值在给定参数μ,σ^2的条下的联合概率为：$p(\mathbf{x}|\mu,\sigma^2)=\prod_{n=1}^{N}\mathcal{N}(x_n|\mu,\sigma^2)$
- 要依据观测值$\mathbf{x}=(x_1,x_2,\cdots,x_N)^T$对参数（分布）进行估计
- 最朴素的原则就是找到一组参数，使似然函数值最大——极大似然参数估计
- 在正态分布情况下，为求解方便，对似然函数取自然对数，得到：

$$\ln p(\mathbf{x}|\mu,\sigma^2)=-\frac{1}{2\sigma^2}\sum_{n=1}^{N}(x_n-\mu)^2-\frac{N}{2}\ln\sigma^2-\frac{N}{2}\ln(2\pi)$$



Likelihood function

$$p(\mathbf{x}|\mu,\sigma^2)=\prod_{n=1}^{N}\mathcal{N}\left(x_n|\mu,\sigma^2\right)$$

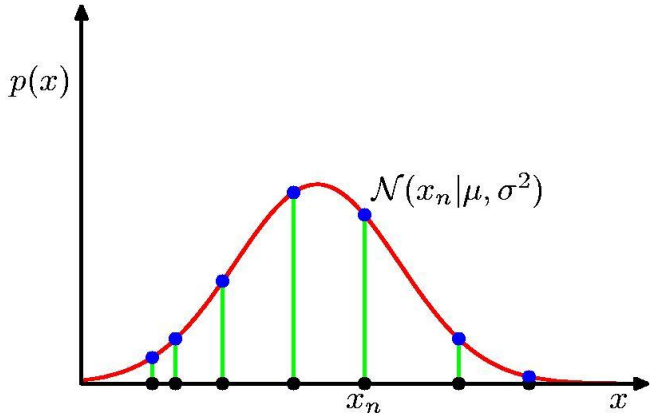
- 上式求极值，求一阶导数并令导数=0，可得：

$$\begin{cases}\dfrac{d\ln p(\mathbf{x}|\mu,\sigma^2)}{d\mu}=\dfrac{1}{\sigma^2}\displaystyle\sum_{n=1}^{N}(x_n-\mu)=0\\[2ex]\dfrac{d\ln p(\mathbf{x}|\mu,\sigma^2)}{d\sigma^2}=\dfrac{1}{2\sigma^4}\displaystyle\sum_{n=1}^{N}(x_n-\mu)^2-\dfrac{N}{2\sigma^2}=0\end{cases}$$

二、最小二乘曲线拟合的概率意义-基础概率知识回顾

$$\mathcal{N}\left(x|\mu,\sigma^2\right)=\frac{1}{(2\pi\sigma^2)^{1/2}}\exp\left\{-\frac{1}{2\sigma^2}(x-\mu)^2\right\}$$

$$\begin{cases}\dfrac{d\ln p(\mathbf{x}|\mu,\sigma^2)}{d\mu}=\dfrac{1}{\sigma^2}\displaystyle\sum_{n=1}^{N}(x_n-\mu)=0\\[2ex]\dfrac{d\ln p(\mathbf{x}|\mu,\sigma^2)}{d\sigma^2}=\dfrac{1}{2\sigma^4}\displaystyle\sum_{n=1}^{N}(x_n-\mu)^2-\dfrac{N}{2\sigma^2}=0\end{cases}$$



Likelihood function

$$p(\mathbf{x}|\mu,\sigma^2)=\prod_{n=1}^{N}\mathcal{N}\left(x_n|\mu,\sigma^2\right)$$

求解上式，可得：

$$\begin{cases}\mu=\dfrac{1}{N}\displaystyle\sum_{n=1}^{N}x_n\\[2ex]\sigma^2=\dfrac{1}{N}\displaystyle\sum_{n=1}^{N}(x_n-\mu)^2\end{cases}$$

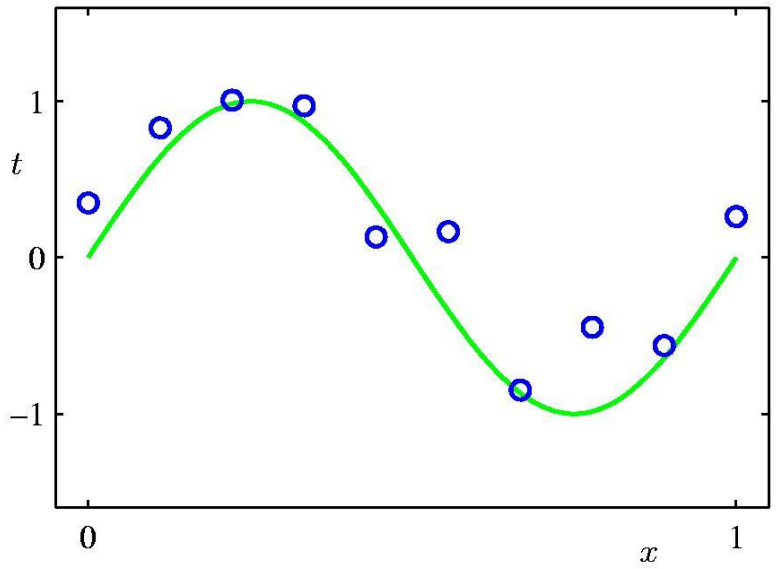
思考：期望如果是函数，极大似然估计会如何？

$$\ln p(\mathbf{x}|\mu,\sigma^2)=-\frac{1}{2\sigma^2}\sum_{n=1}^{N}(x_n-\mu)^2-\frac{N}{2}\ln\sigma^2-\frac{N}{2}\ln(2\pi)$$

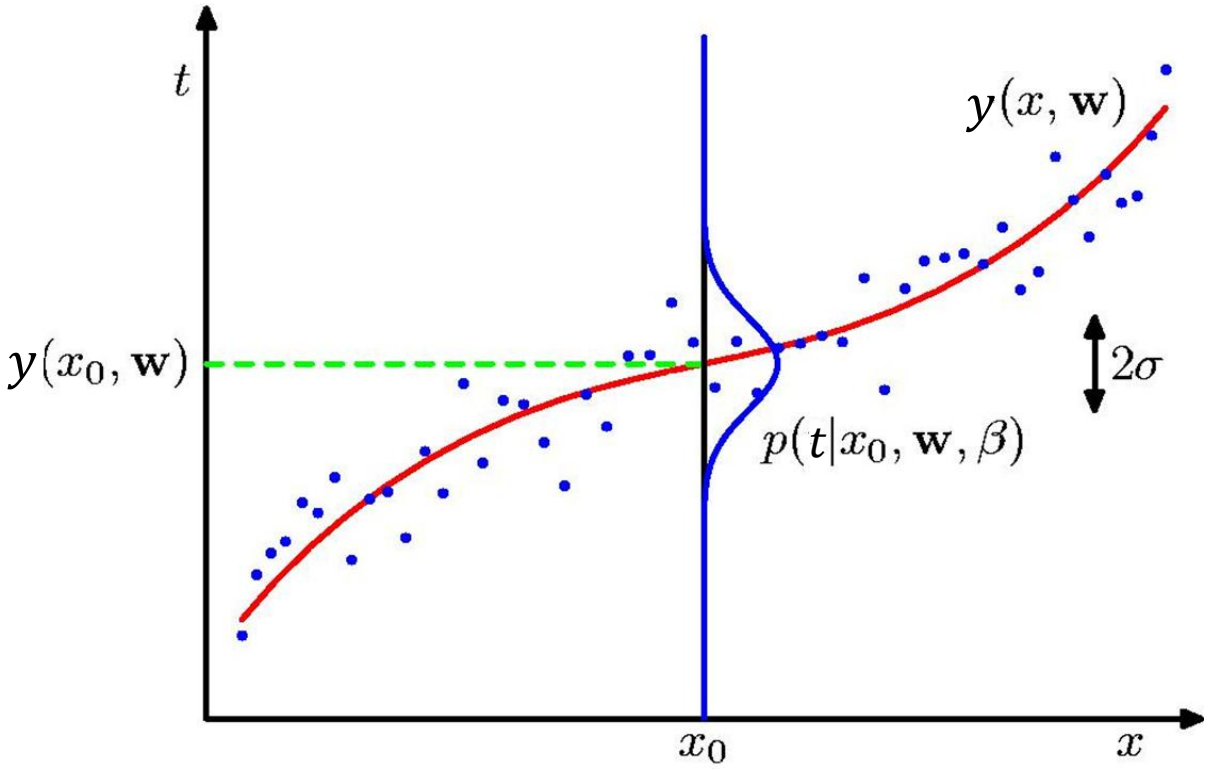
回顾、思考：上述参数估计是否无偏。如果有偏，无偏估计是什么？

无偏：参数的估计量的期望值等于该参数的真实值

二、最小二乘曲线拟合的概率意义



$$y(x,\mathbf{w}) = w_0 + w_1x^1 + w_2x^2, \ldots, +w_Mx^M = \sum_{i=0}^{M} w_ix^i$$

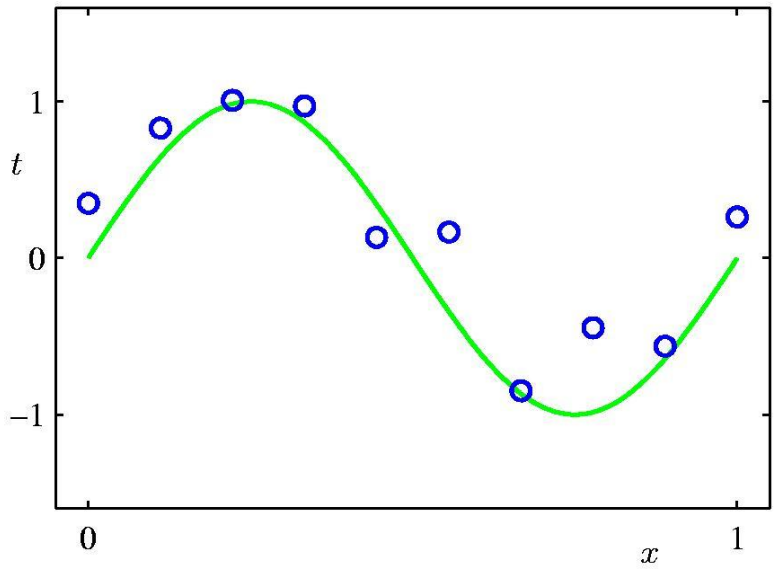


二、最小二乘曲线拟合的概率意义

- 假定随机变量t服从正态分布

$$\mathcal{N}(t|w_0x^0 + w_1x^1 +, \dots, +w_Mx^M, \sigma^2)$$

$$\mathbf{x}_n = \begin{pmatrix} x_n^0 \\ x_n^1 \\ \vdots \\ x_n^M \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_M \end{pmatrix}$$



- 对t观测N=10次，获得i.i.d. 数据集 $\mathbf{t} = (t_1, t_2, \dots, t_N)^T$
- $\mathbf{t}$的自然对数似然函数为$\ln p(\mathbf{t}|\mathbf{w}, \sigma^2) = \ln \prod_{n=1}^{N} \mathcal{N}(t_n|\mathbf{w}^T\mathbf{x}_n, \sigma^2)$

$$\ln p(\mathbf{t}|\mathbf{w}, \sigma^2) = -\frac{1}{2\sigma^2}\sum_{n=1}^{N}(t_n - \mathbf{w}^T\mathbf{x}_n)^2 - \frac{N}{2}\ln\sigma^2 - \frac{N}{2}\ln(2\pi)$$

- **回顾多项式曲线拟合的损失函数**

$$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{X}\mathbf{w} - \mathbf{t}\|^2 = \frac{1}{2}\sum_{n=1}^{N}(t_n - \mathbf{w}^T\mathbf{x}_n)^2$$

$$y(x, \mathbf{w}) = w_0 + w_1x^1 + w_2x^2, \dots, +w_Mx^M = \sum_{i=0}^{M} w_ix^i$$

最大化似然函数，相当于最小化二范数损失（欧式距离度量的拟合误差），二者等价！！！

3 损失函数与最优化方法

三、最小二乘曲线拟合的解法-损失函数

最小二乘曲线拟合中，以2范数（欧式距离）作为损失函数度量了模型与观测数据间的偏差

$$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{Xw} - \mathbf{t}\|^2$$

机器学习中的其他损失函数：

① 0-1损失：$L(\mathbf{w}) = \begin{cases} 1, |y(\mathbf{x}) - t| > T \\ 0, |y(\mathbf{x}) - t| \le T \end{cases}$

② 绝对值损失（1范数）：正则化与稀疏解$L(\mathbf{w}) = \sum|y(\mathbf{x}) - t|$

③ 对数损失（交叉熵损失）：$L(\mathbf{w}) = -\{t\ln y(\mathbf{x}) + (1-t)\ln(1-y(\mathbf{x}))\}$

④ 指数损失：Adaboost $L(\mathbf{w}) = exp[-ty((\mathbf{x}))]$

⑤ Hinge损失：SVM $L(\mathbf{w}) = max(0, 1 - ty((\mathbf{x}))$

⑥ **感知损失：Hinge损失的变种**$L(\mathbf{w}) = max(0, 1 - y((\mathbf{x}))$

⑦ 投影距离损失：主成分分析（Principle Component Analysis）

⑧ 计算机视觉问题中的专用损失函数：IOU、FocalLoss等

⑨ 其他

三、最小二乘曲线拟合的解法-参数迭代求解

$$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{X}\mathbf{w} - \mathbf{t}\|^2$$

1. 大部分情况下，损失函数对w求导后不能获得可以直接求解的线性方程组。

   ■ 可采用先给定初值，再迭代求解的策略。w的初值如何给定?

2. 如果数据量巨大，迭代速度会很慢。

   ■ 使用部分数据的损失类替代理想损失（全部数据的损失），逐批加入数据，遍历全部数据一次后，完成一次迭代更新，一个Epoch。

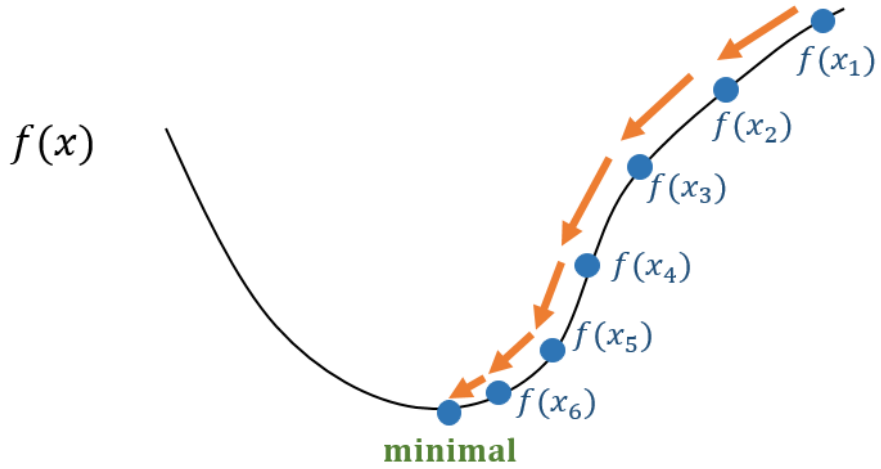
3. 数据量很大时，即使损失函数求导可以直接求得w，也不直接计算。例如最小二乘中的$\mathbf{X}^T\mathbf{X}, (N \times N)$。

   ■ 采用上述的迭代方法。

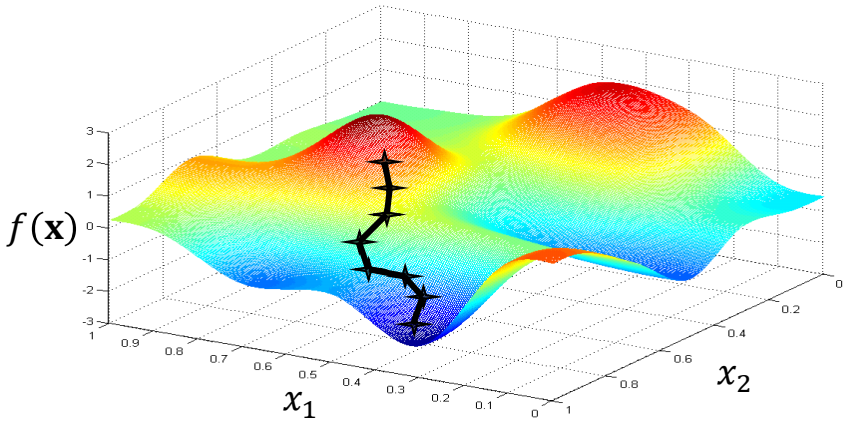
$$\mathbf{w} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{t} \qquad \mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{pmatrix}, \quad N \times (M+1)$$

三、最小二乘曲线拟合的解法-优化方法：梯度下降法

$$f(x)=f(x_0)+f'(x_0)(x-x_0)+\frac{f''(x_0)}{2!}(x-x_0)^2+\cdots+\frac{f^{(n)}(x_0)}{n!}(x-x_0)^n+\cdots$$



$f(x^{t+1})<f(x^t)$



$f(\mathbf{x}^{t+1})<f(\mathbf{x}^t),\ \mathbf{x}=(x_1,x_2)$

$f(\mathbf{x}+\Delta\mathbf{x})$在$\mathbf{x}$处的一阶泰勒展开$f(\mathbf{x}+\Delta\mathbf{x})\cong f(\mathbf{x})+\Delta\mathbf{x}\nabla f(\mathbf{x})$

思考：搜索函数极小值，$\Delta\mathbf{x}$应该为正还是负（朝哪个方向前进）？前进多少？

由$f(\mathbf{x}+\Delta\mathbf{x})<f(\mathbf{x})$ 可知 $\Delta\mathbf{x}\nabla f(\mathbf{x})<0$，因此，可以选择$\Delta\mathbf{x}=-\eta\nabla f(\mathbf{x})$，$\eta>0$是一个较小的正数（学习率）。

沿梯度的反方向前进，函数值下降！ 如果用二阶泰勒展开?

三、最小二乘曲线拟合的解法-梯度下降法

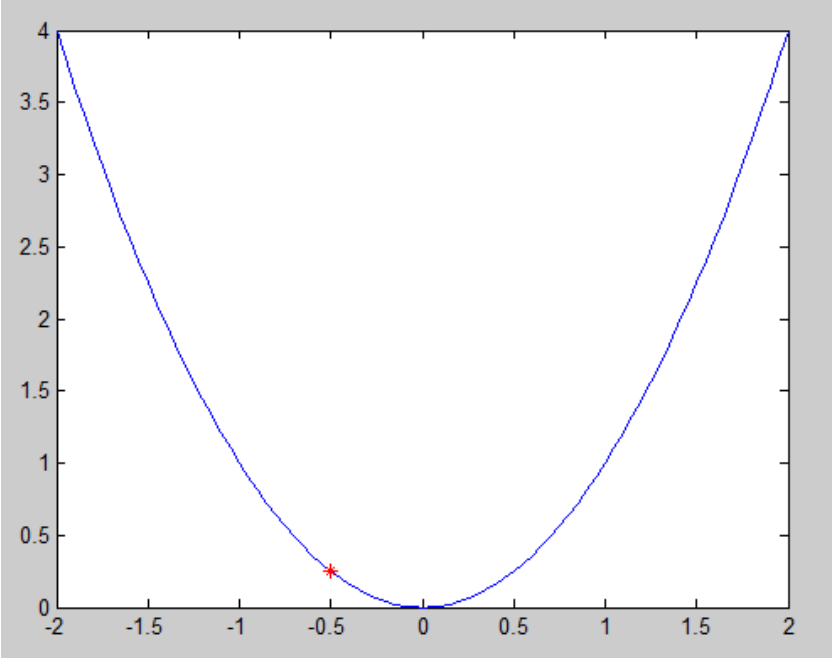
回顾最小二乘曲线拟合 $Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{Xw} - \mathbf{t}\|^2$ $\nabla Loss(\mathbf{w}) = \mathbf{X}^T(\mathbf{Xw} - \mathbf{t})$

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_N^T \end{pmatrix} = \begin{pmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{pmatrix} \quad \mathbf{t} = \begin{pmatrix} t_0 \\ t_1 \\ \vdots \\ t_N \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_M \end{pmatrix}$$

迭代求解方法： $\Delta\mathbf{w} = -\eta\nabla Loss(\mathbf{w}) = -\eta\mathbf{X}^T(\mathbf{Xw} - \mathbf{t})$

解析求解方法： $\nabla Loss(\mathbf{w}^*) = \mathbf{X}^T(\mathbf{Xw}^* - \mathbf{t}) = 0$

- **如果迭代到最优解后，梯度为0，迭代法不再下降。**
- **靠近最优解，梯度逐渐减小。**
- **远离最优解的区域，梯度比较大。**



三、最小二乘曲线拟合的解法-梯度下降法

$$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{Xw} - \mathbf{t}\|^2 = \frac{1}{2}\sum_{n=1}^{N}(\mathbf{w}^T\mathbf{x}_n - t_n)^2$$

1. 批量梯度下降法BGD(Batch Gradient Descent)： 每次更新模型使用所有数据计算损失

   - 优点：全局最优解（对于凸函数）；易于并行实现
   - 缺点：当数据很多时，计算量开销大，计算速度慢

2. 小批量梯度下降法MBGD（mini-batch Gradient Descent）：每次更新模型使用部分数据计算损失

   - 优点：减少了计算的开销量，降低了随机性，计算速度比较快

3. 随机梯度下降法SGD（stochastic gradient descent）： 每次更新模型使用一个数据计算损失

   - 优点：计算速度快
   - 缺点：收敛性能不好，抖动

三、最小二乘曲线拟合的解法-其他优化方法

1. **自变量为变量（向量、标量等）**
   a. 一阶导数搜索（最速下降法）：
      - 梯度下降法，BGD,MBGD,SGD等
      - 惯量法，保持搜索的惯性（搜索方向），Momentum、Nesterov Momentum等
      - 自适应学习率法，自适应更新不同参数的学习率，Adagrad、Adadelta、RMSprop、Adam等

   b. 二阶导数搜索（比最速下降法下降的更快）
      - 牛顿法，快，不稳定，计算量大
      - 拟牛顿法，牛顿法的简化（二次导数矩阵）

        *二阶泰勒展开

   c. 共轭梯度法：介于一阶和二阶导数方法之间

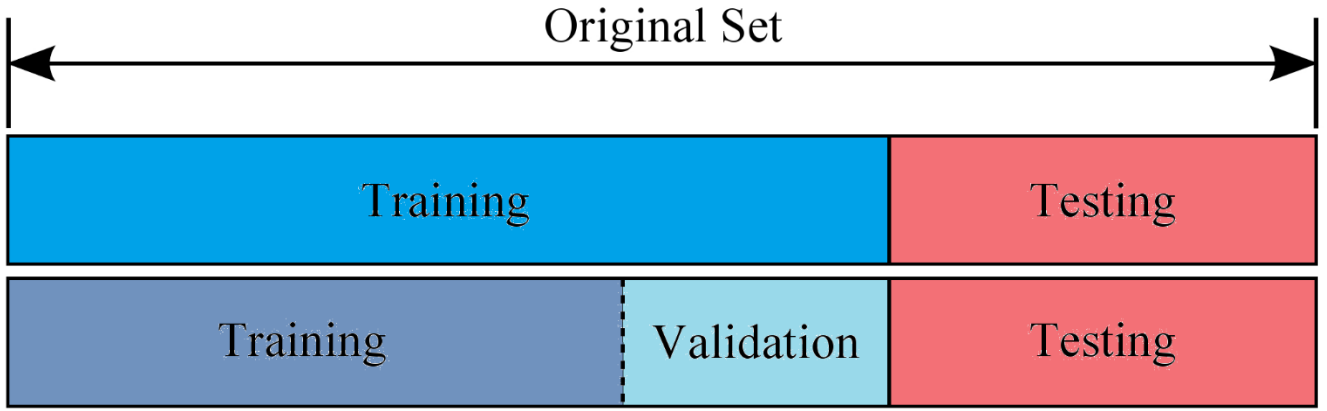
   d. 分治法：坐标下降法、Sequential Minimal Optimization(SMO)（支持向量机一般采用此类方法）

   e. 启发式搜索：遗传算法、模拟退火、Graph-Cut

2. **自变量为函数（问题的定义域是函数空间）**
   a. 变分法

4 模型的泛化能力与正则化

四、曲线拟合模型的泛化能力-数据集划分



训练
- 训练集：用来学习模型的参数，权重和偏置，用于梯度下降
- 验证集：用来选择模型超参数，如多项式阶数、神经网络层数等，不参与梯度下降

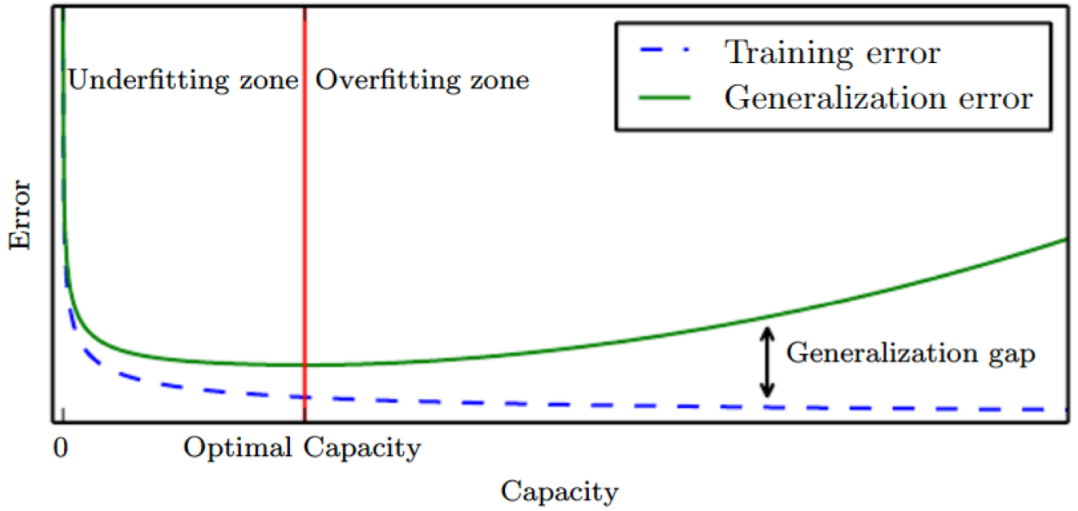
测试
- 测试集：模型训练完毕后，评价模型的效果。

四、曲线拟合模型的泛化能力-数据集划分

1. 数据集：训练集、验证集、测试集
2. 修改模型，减小泛化误差(Generalization error）或测试误差（Test error）
3. 必要的时候会以增加训练误差（Training Error）为代价
4. 即增强模型对没有见过的数据的预测能力

---

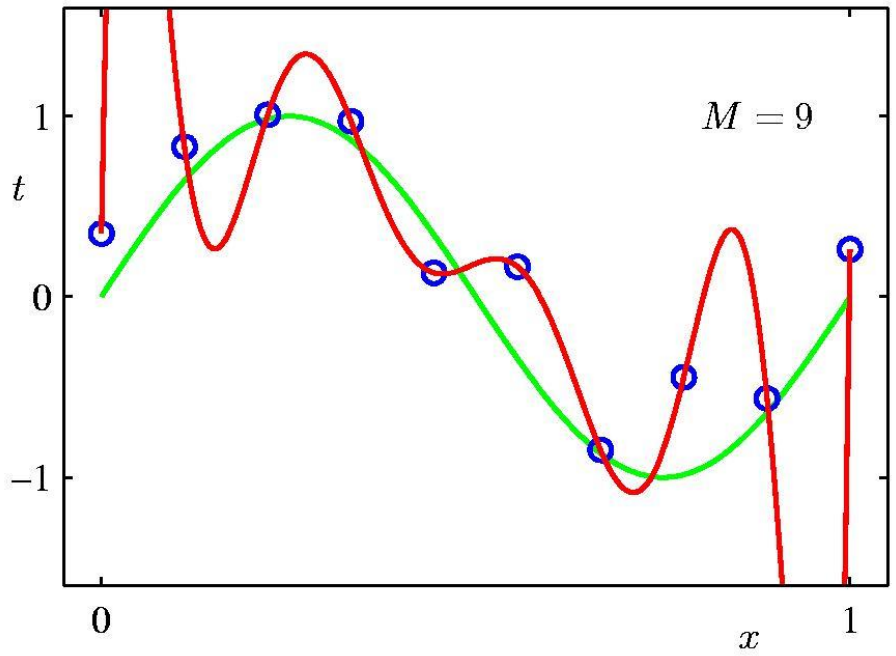
1. 限制模型复杂度以防止过拟合
   - Occam's razor原理（简单有效）：如无必要，勿增实体。
2. 先验知识的引入
   - 以贝叶斯的视角来看问题，引入模型参数的先验分布。



四、曲线拟合模型的泛化能力-过拟合与模型复杂度

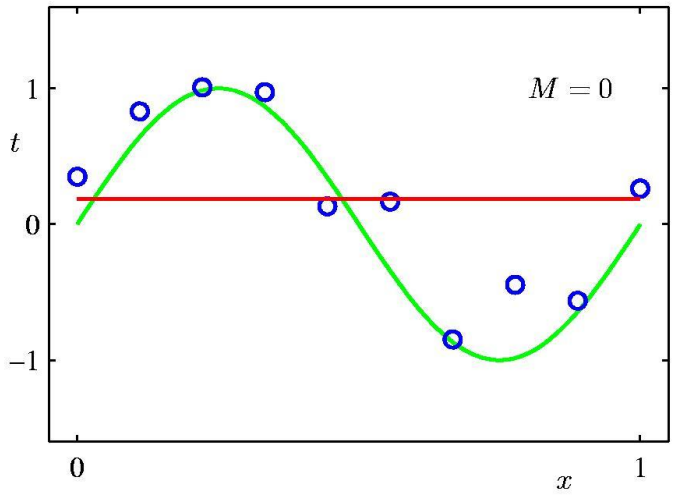
1. 在本例中，如果M足够大，是否可以使损失为0?
2. 是否应该让M取尽量大的值，从而使损失越小越好?
3. 10个数据，9阶多项式。

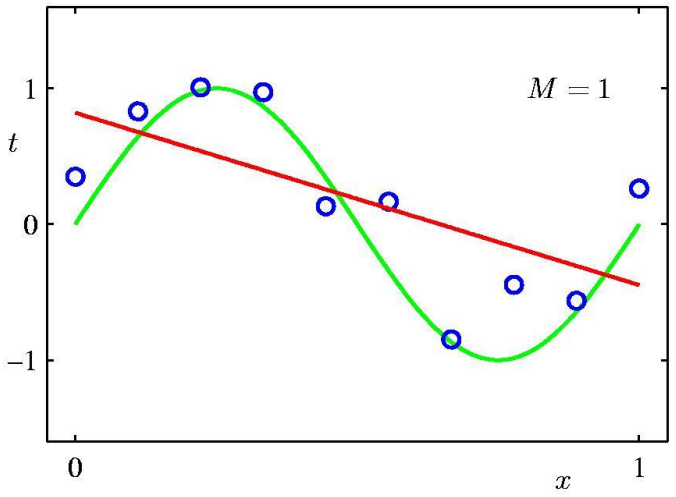
$$Loss(\mathbf{w}) = \frac{1}{2}\|\mathbf{\Phi w} - \mathbf{t}\|^2$$

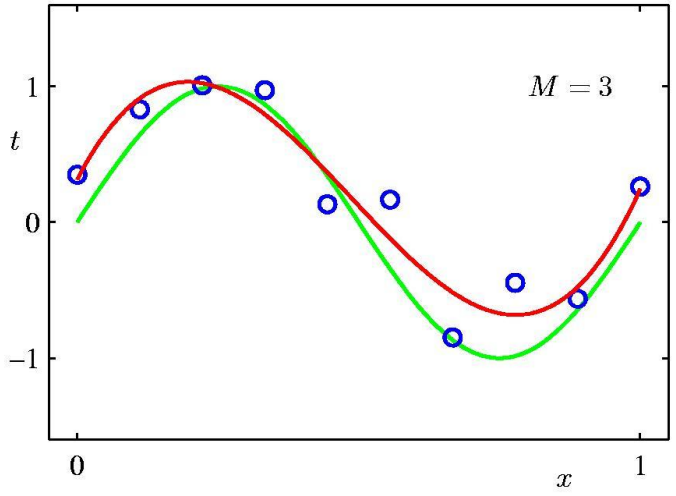


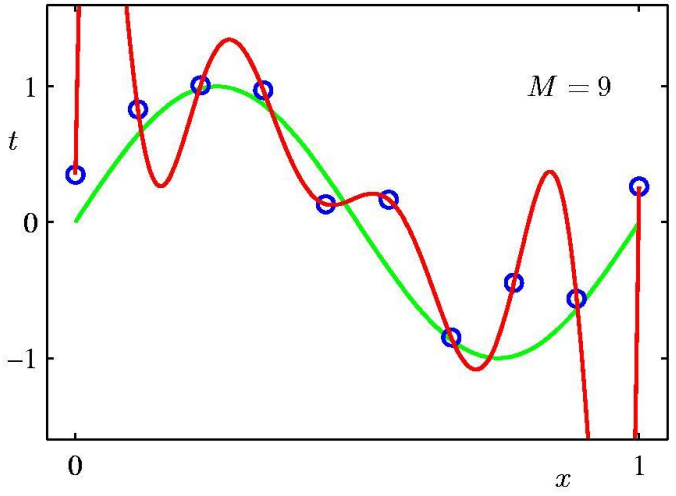
四、曲线拟合模型的泛化能力-过拟合与模型复杂度

样本个数N=10



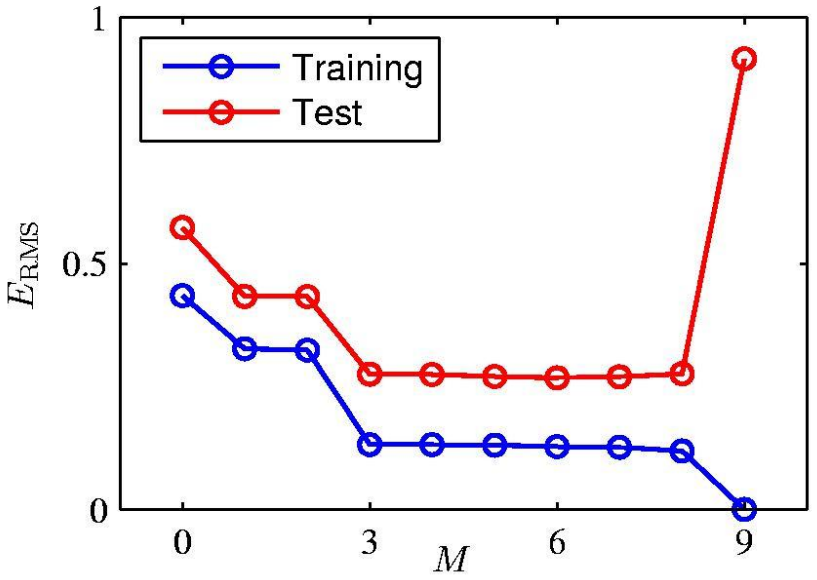






样本个数与模型复杂度要匹配

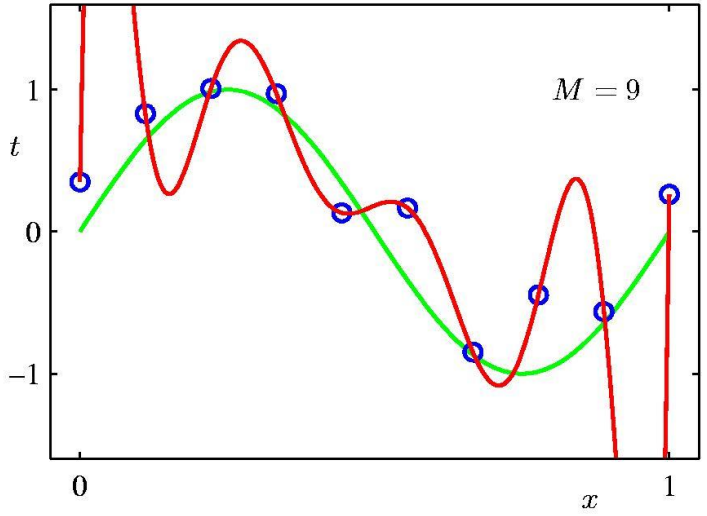
过拟合



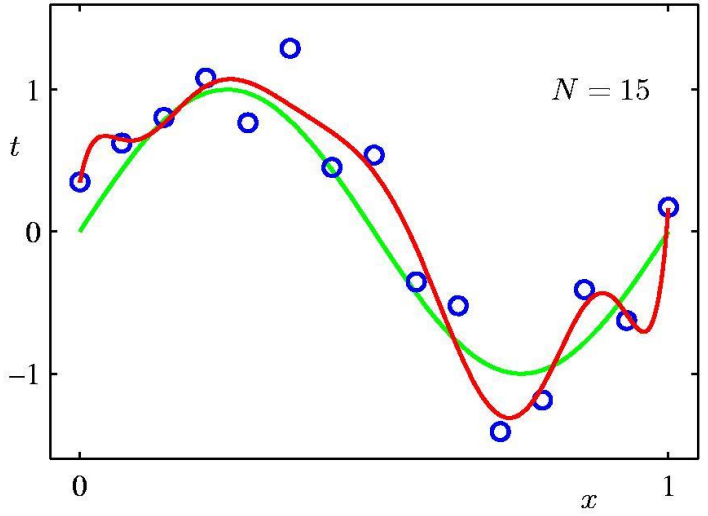
四、曲线拟合模型的泛化能力-过拟合与模型复杂度

M =9, 9th Order Polynomial

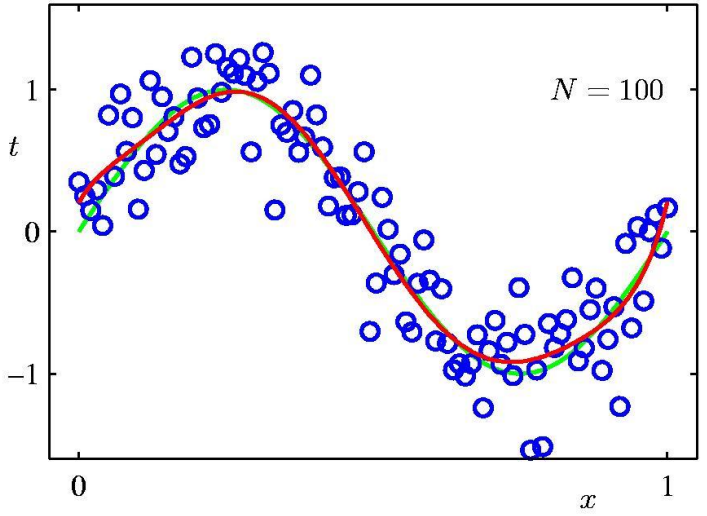
样本个数N=10



样本个数N=15



样本个数N=100



四、曲线拟合模型的泛化能力-过拟合与模型复杂度

	$M=0$	$M=1$	$M=3$	$M=9$
$w_0^\star$	0.19	0.82	0.31	0.35
$w_1^\star$		-1.27	7.99	232.37
$w_2^\star$			-25.43	-5321.83
$w_3^\star$			17.37	48568.31
$w_4^\star$				-231639.30
$w_5^\star$				640042.26
$w_6^\star$				-1061800.52
$w_7^\star$				1042400.18
$w_8^\star$				-557682.99
$w_9^\star$				125201.43

过拟合模型的系数非常大

四、曲线拟合模型的泛化能力-正则化

	$M=0$	$M=1$	$M=3$	$M=9$
$w_0^\star$	0.19	0.82	0.31	0.35
$w_1^\star$		-1.27	7.99	232.37
$w_2^\star$			-25.43	-5321.83
$w_3^\star$			17.37	48568.31
$w_4^\star$				-231639.30
$w_5^\star$				640042.26
$w_6^\star$				-1061800.52
$w_7^\star$				1042400.18
$w_8^\star$				-557682.99
$w_9^\star$				125201.43

1. 在M给定的情况下，如何避免过拟合?
2. 正则化，加入对模型系数w的惩罚项

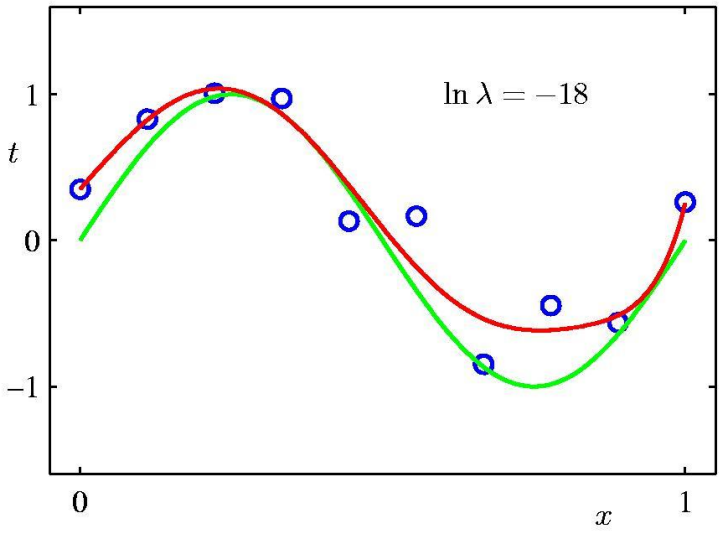
$$Loss_{L2}(\mathbf{w}) = \frac{1}{2}\|\mathbf{Xw}-\mathbf{t}\|^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2$$

(L2)

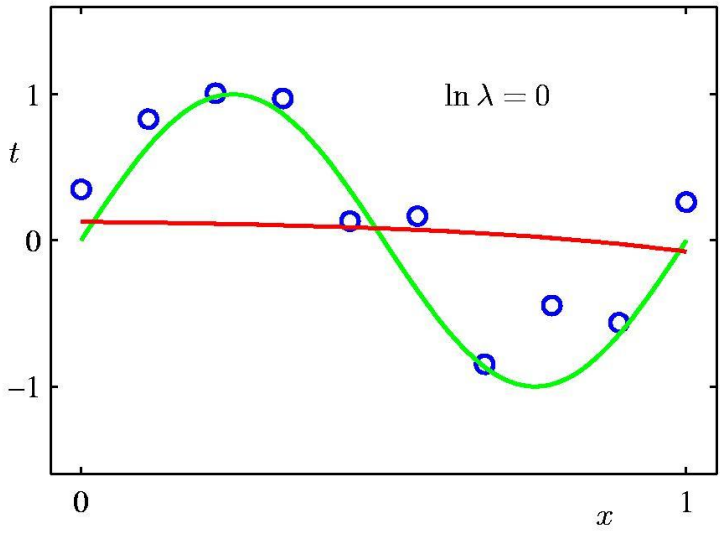
权重衰减（Decay），压缩

四、曲线拟合模型的泛化能力-正则化

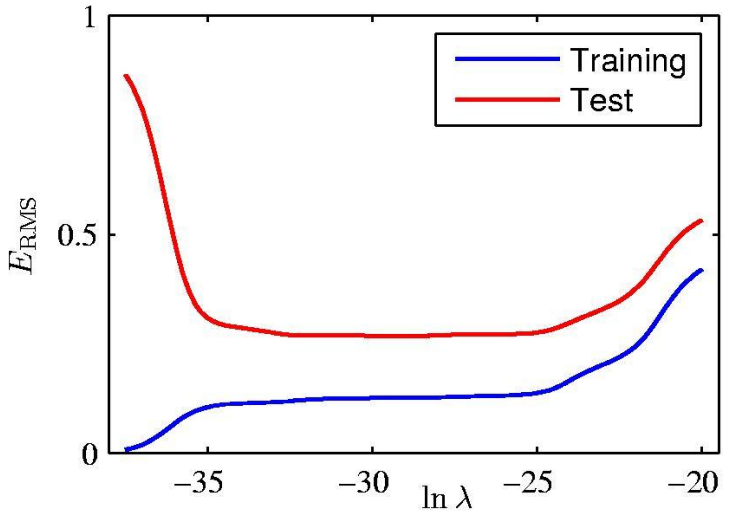
M =9, 9th Order Polynomial



惩罚适度



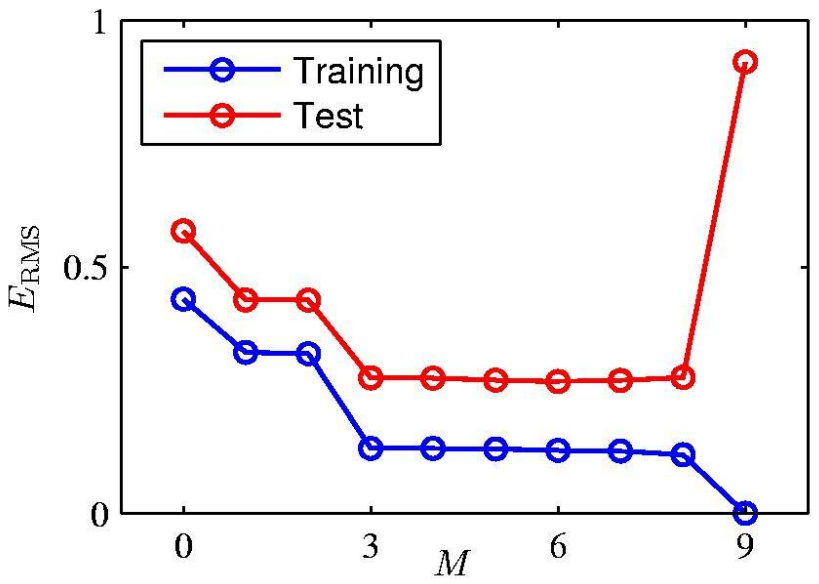
惩罚过度



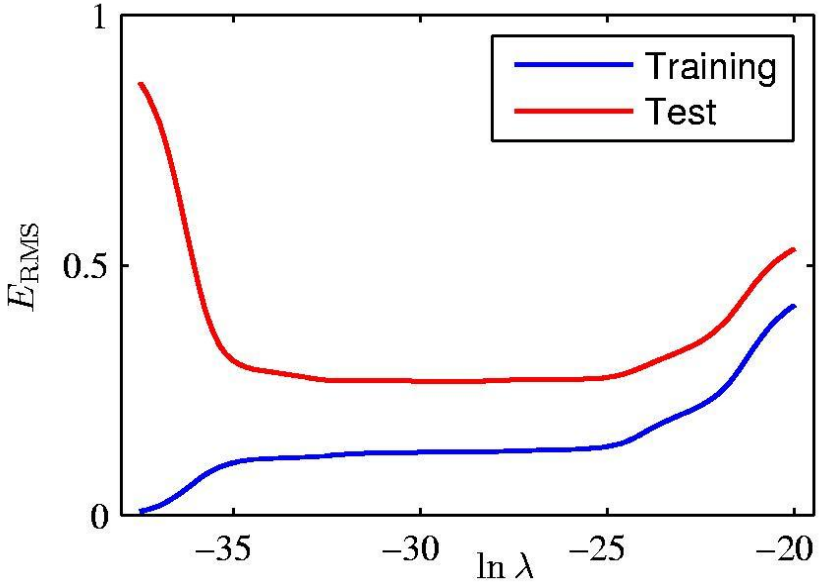
四、曲线拟合模型的泛化能力-正则化

	$\ln\lambda = -\infty$	$\ln\lambda = -18$	$\ln\lambda = 0$
$w_0^\star$	0.35	0.35	0.13
$w_1^\star$	232.37	4.74	-0.05
$w_2^\star$	-5321.83	-0.77	-0.06
$w_3^\star$	48568.31	-31.97	-0.05
$w_4^\star$	-231639.30	-3.89	-0.03
$w_5^\star$	640042.26	55.28	-0.02
$w_6^\star$	-1061800.52	41.32	-0.01
$w_7^\star$	1042400.18	-45.95	-0.00
$w_8^\star$	-557682.99	-91.53	0.00
$w_9^\star$	125201.43	72.68	0.01
	近似无惩罚	惩罚适度	惩罚过度

四、曲线拟合模型的泛化能力-正则化



模型复杂度从简单到复杂

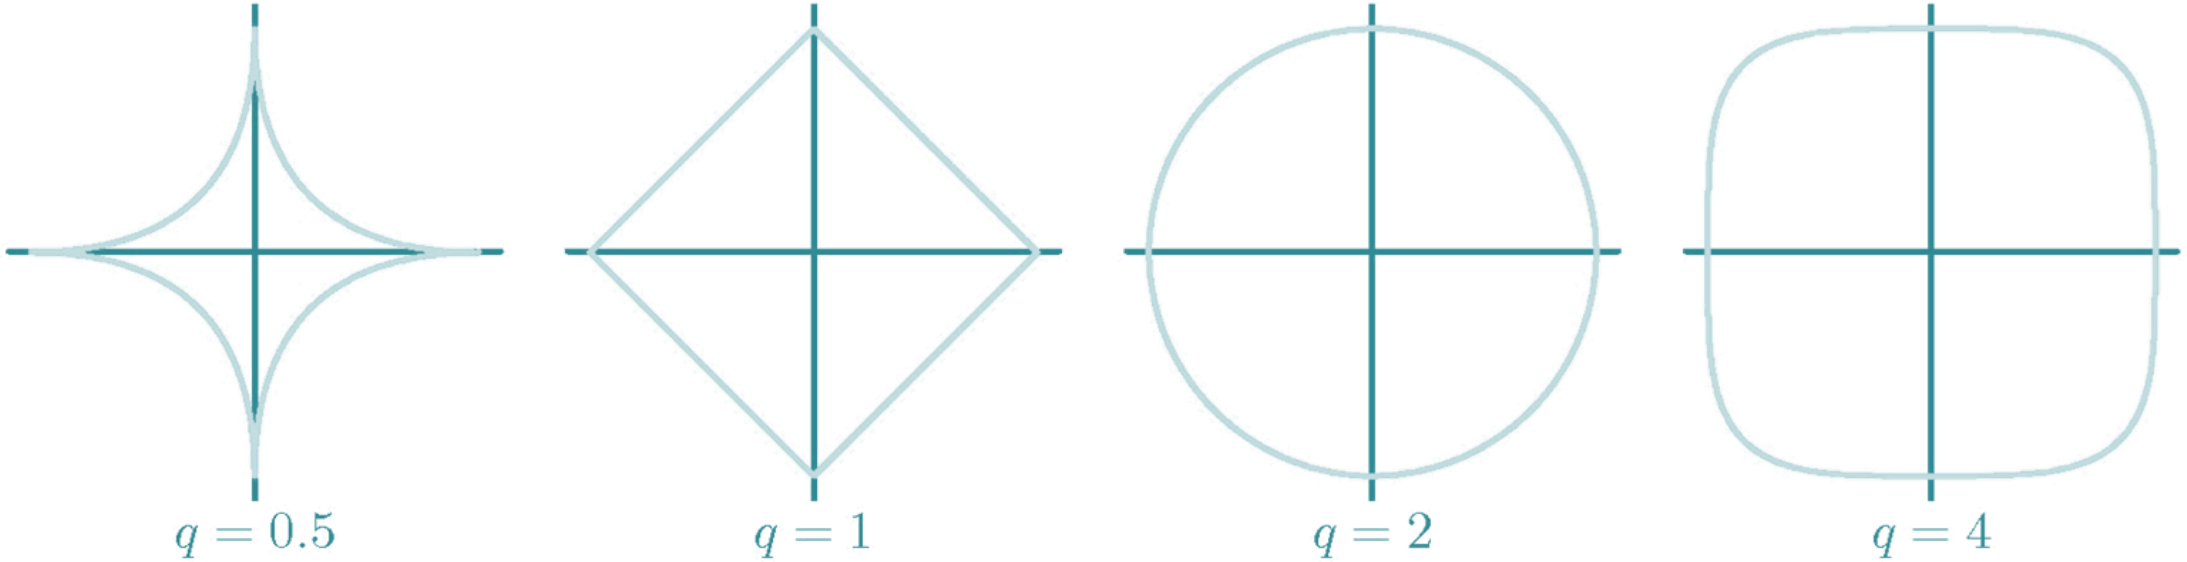


惩罚项权重从小达大

四、曲线拟合模型的泛化能力-正则化

$$Loss_{Lq}(\mathbf{w}) = \frac{1}{2}\|\mathbf{Xw} - \mathbf{t}\|^2 + \frac{\lambda}{2}\|\mathbf{w}\|^q$$

不同的范数值，对应不同的惩罚项函数等值线

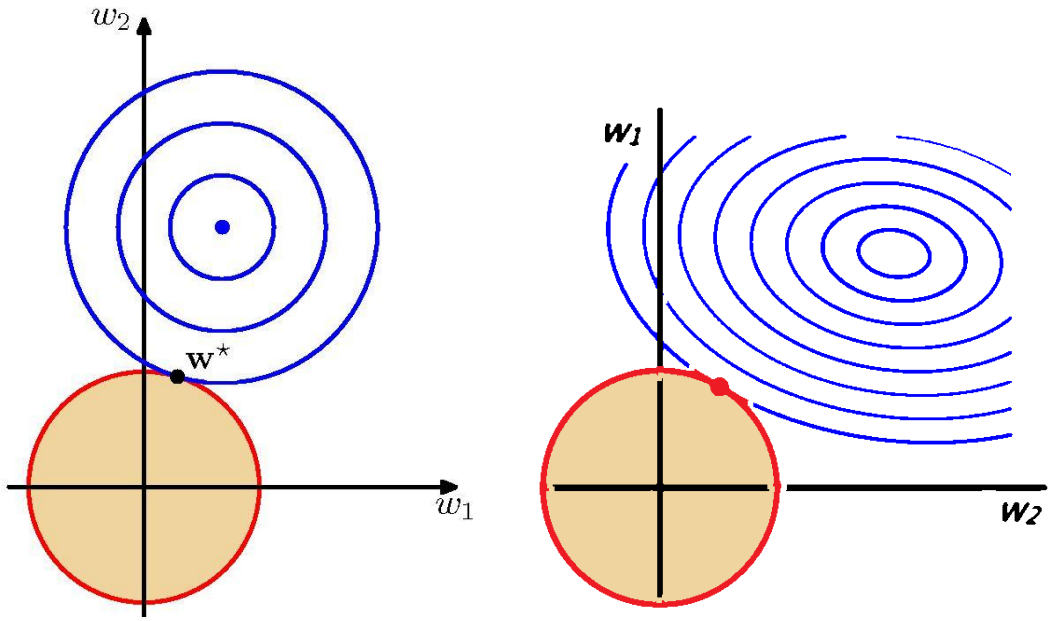


四、曲线拟合模型的泛化能力- L2正则化

$$Loss_{Lq}(\mathbf{w}) = \frac{1}{2}\|\mathbf{Xw}-\mathbf{t}\|^2 + \frac{\lambda}{2}\|\mathbf{w}\|^q = Loss(\mathbf{w}) + \frac{\lambda}{2}\|\mathbf{w}\|^q$$

给定λ的情况下，搜索正则化损失函数极小值，相当于：

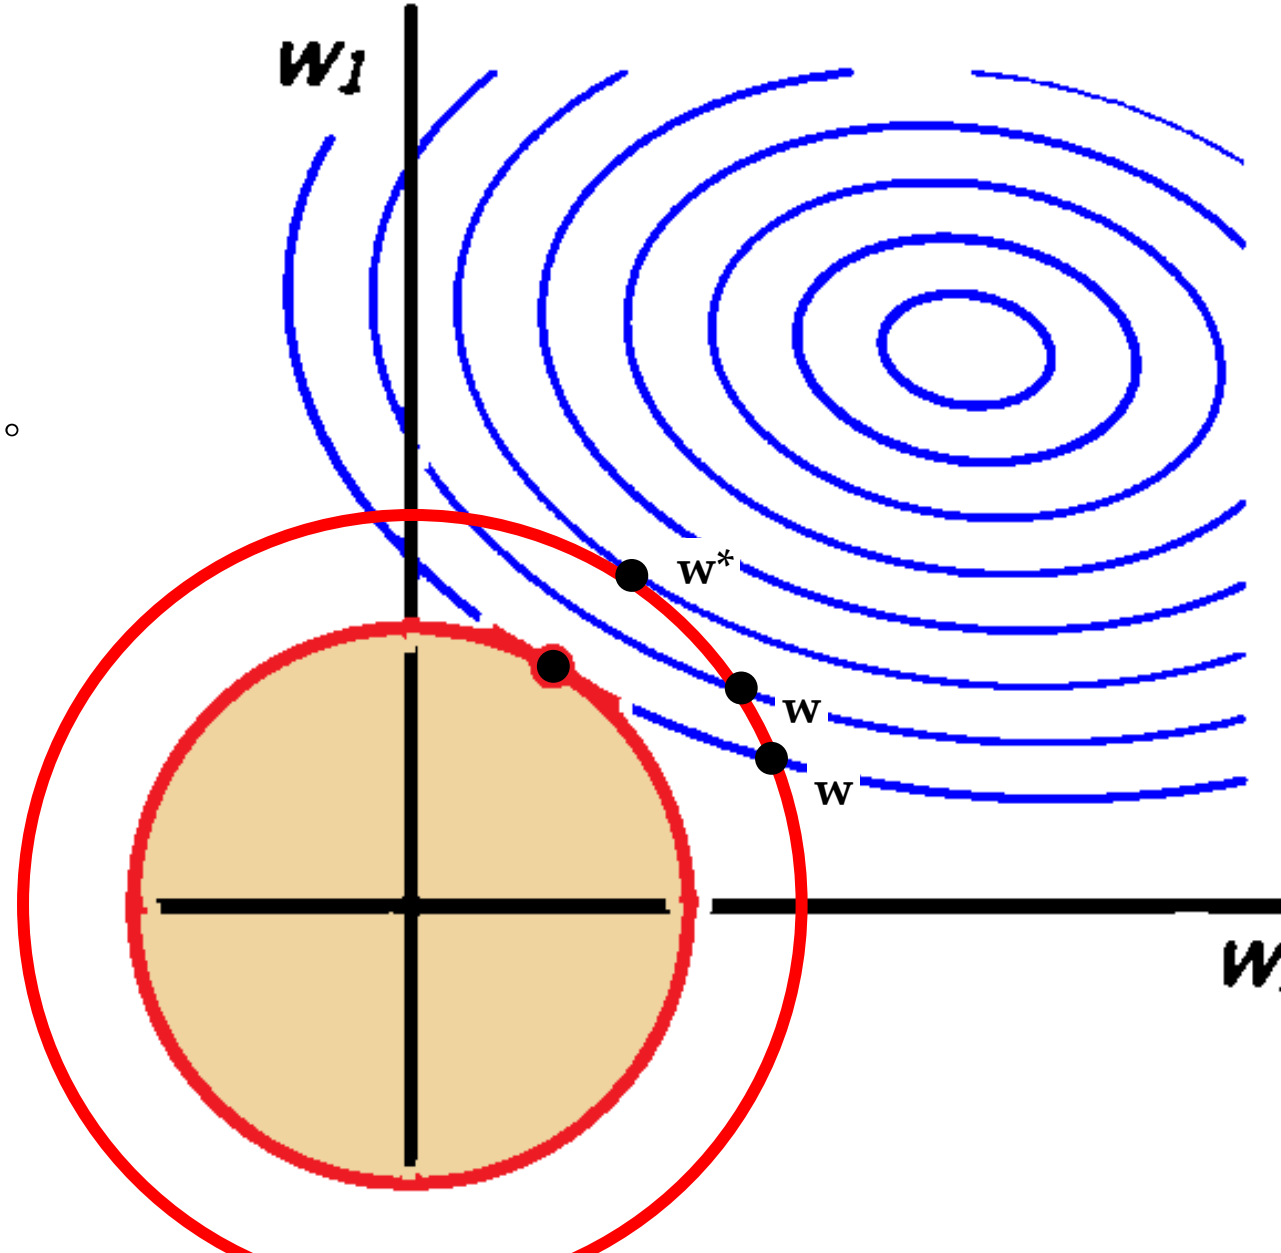
- 给定一个正则化项的等值线，搜索与这个等值线相切的最小损失函数等值线，切点就是w*。



四、曲线拟合模型的泛化能力-L2正则化

- L2范数，假定Loss为凸，对任意w

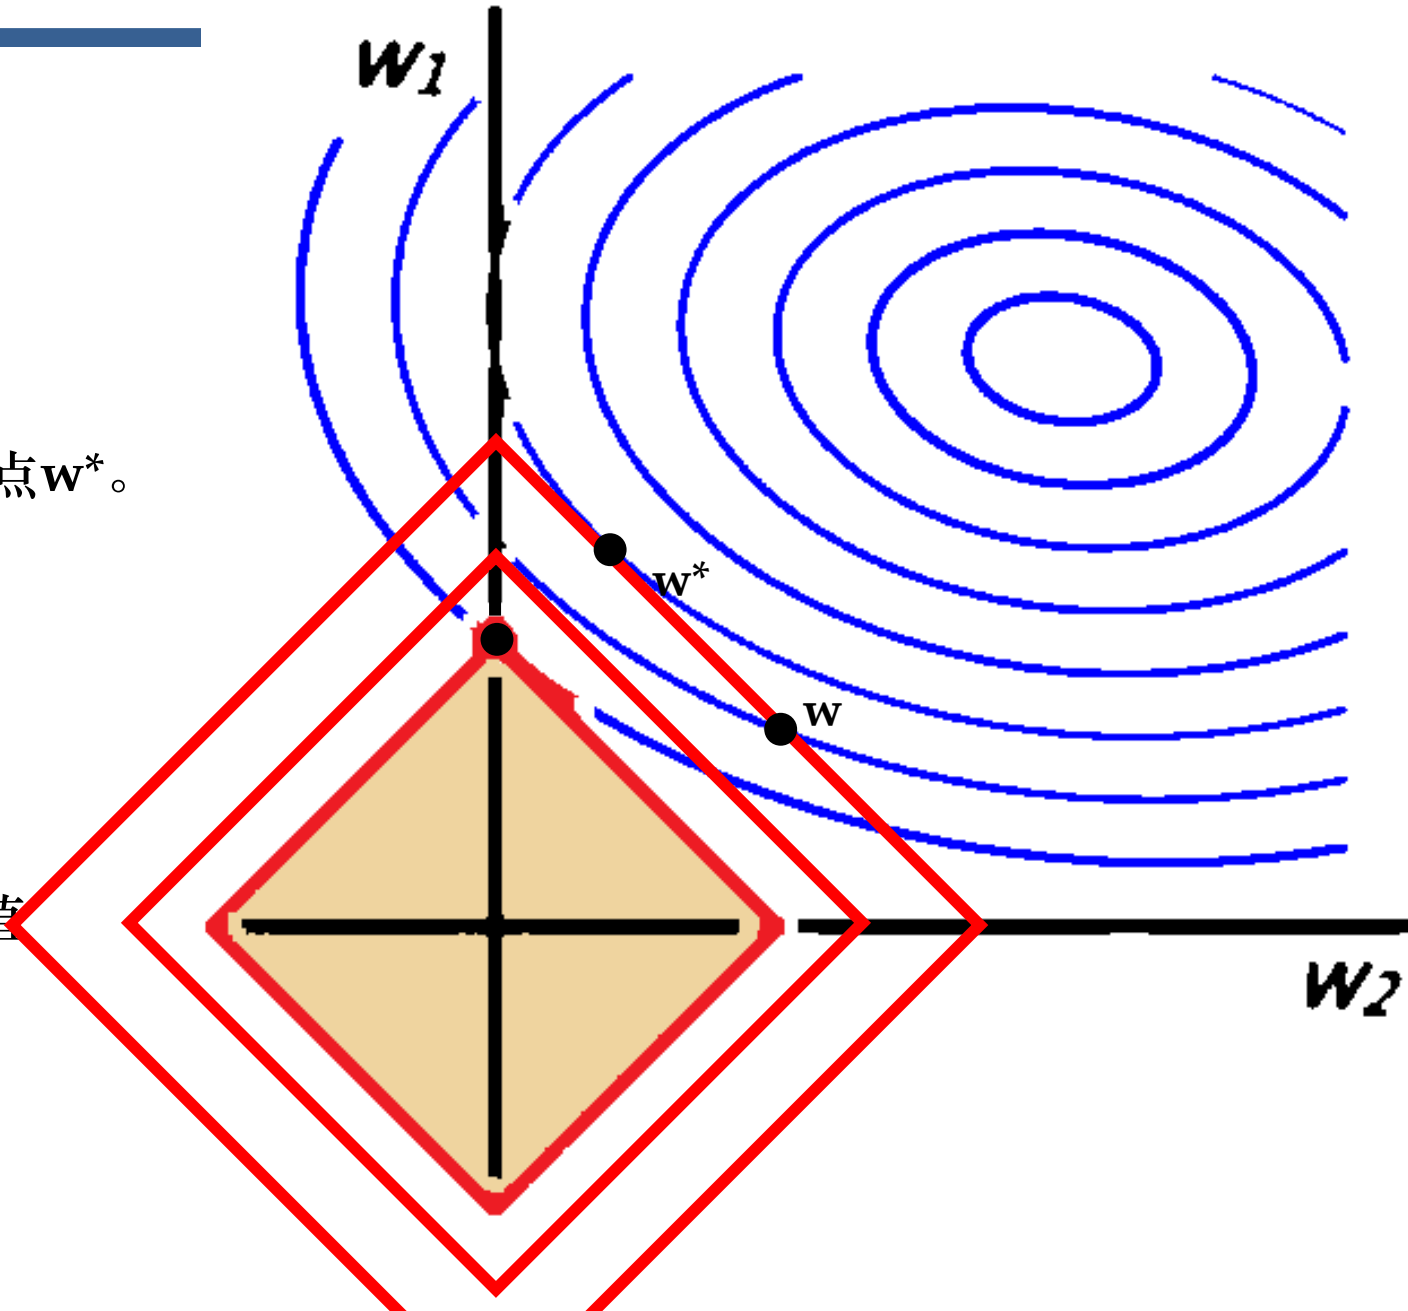
1. 一定可在正则化项等值线上找到一个切点w*。
2. 并且Loss(w*)比Loss(w)小。
3. 即$\frac{\lambda}{2}\|\mathbf{w}^*\|^2$相同，但 $Loss(\mathbf{w}^*)$更小
4. 在无数的w*中，最终的选择取决于λ的值



四、曲线拟合模型的泛化能力-L1正则化

- L1范数，假定Loss为凸，对任意w

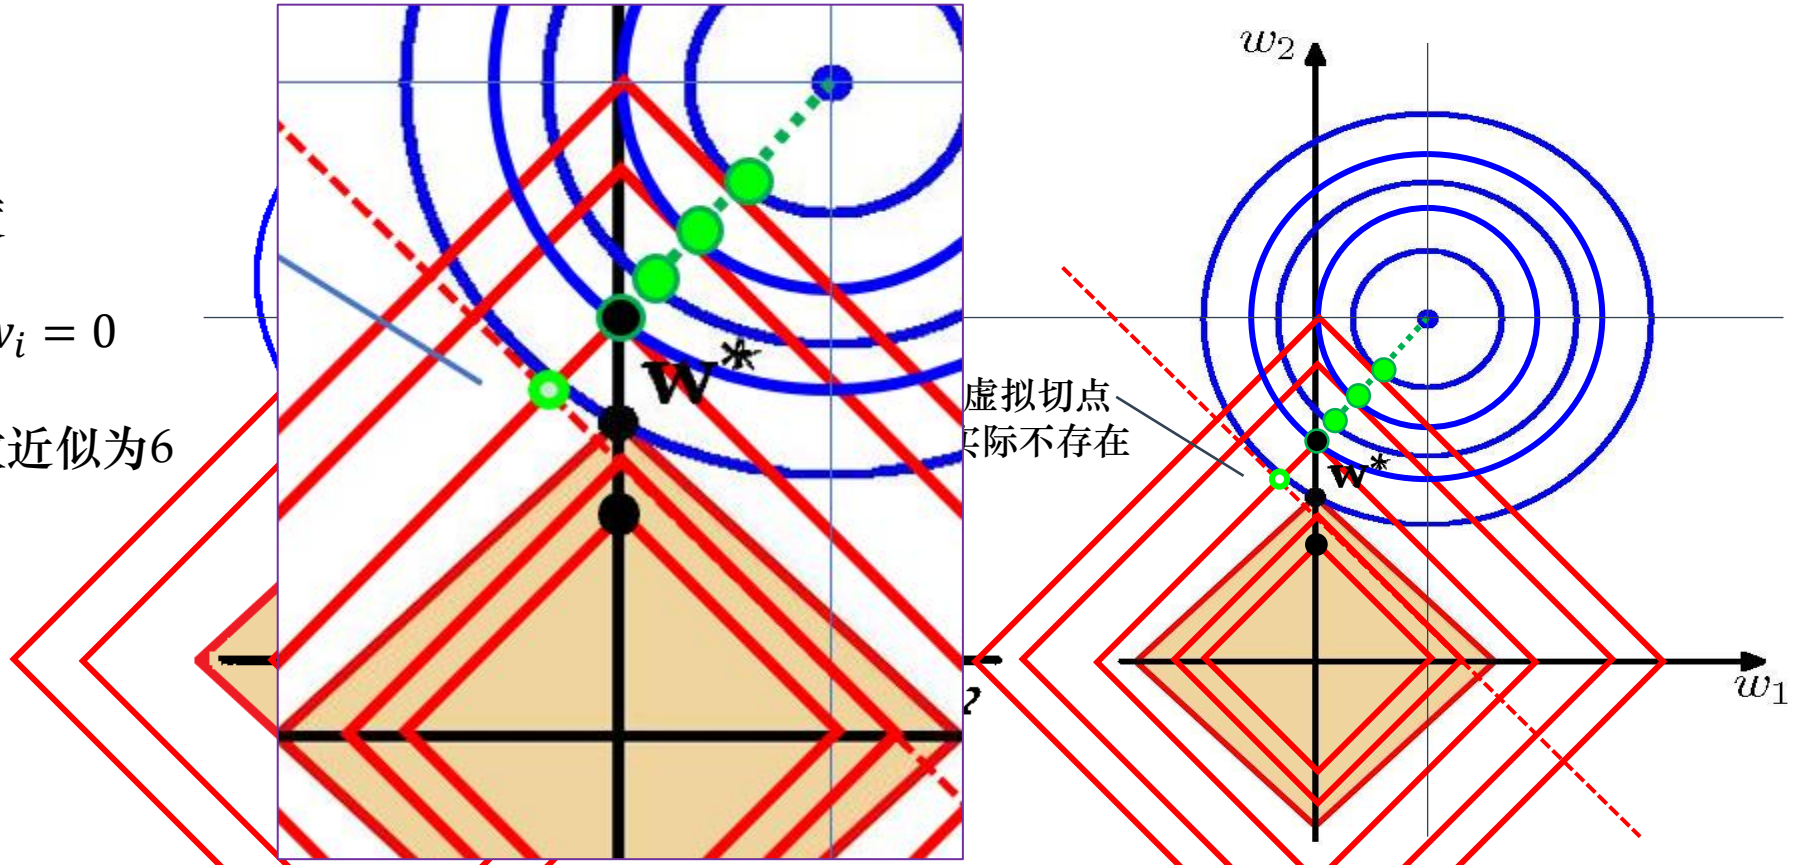
1. 一定可在正则化项等值线上找到一个切点$\mathbf{w}^*$。
2. 并且Loss($\mathbf{w}^*$)比Loss(w)小。
3. 即$\frac{\lambda}{2}\|\mathbf{w}^*\|^1$相同，但 $Loss(\mathbf{w}^*)$更小
4. 在无数的w*中，最终的选择取决于λ的值



四、曲线拟合模型的泛化能力-L1正则化与稀疏解

■ L1范数，假定Loss为凸，对任意**w**

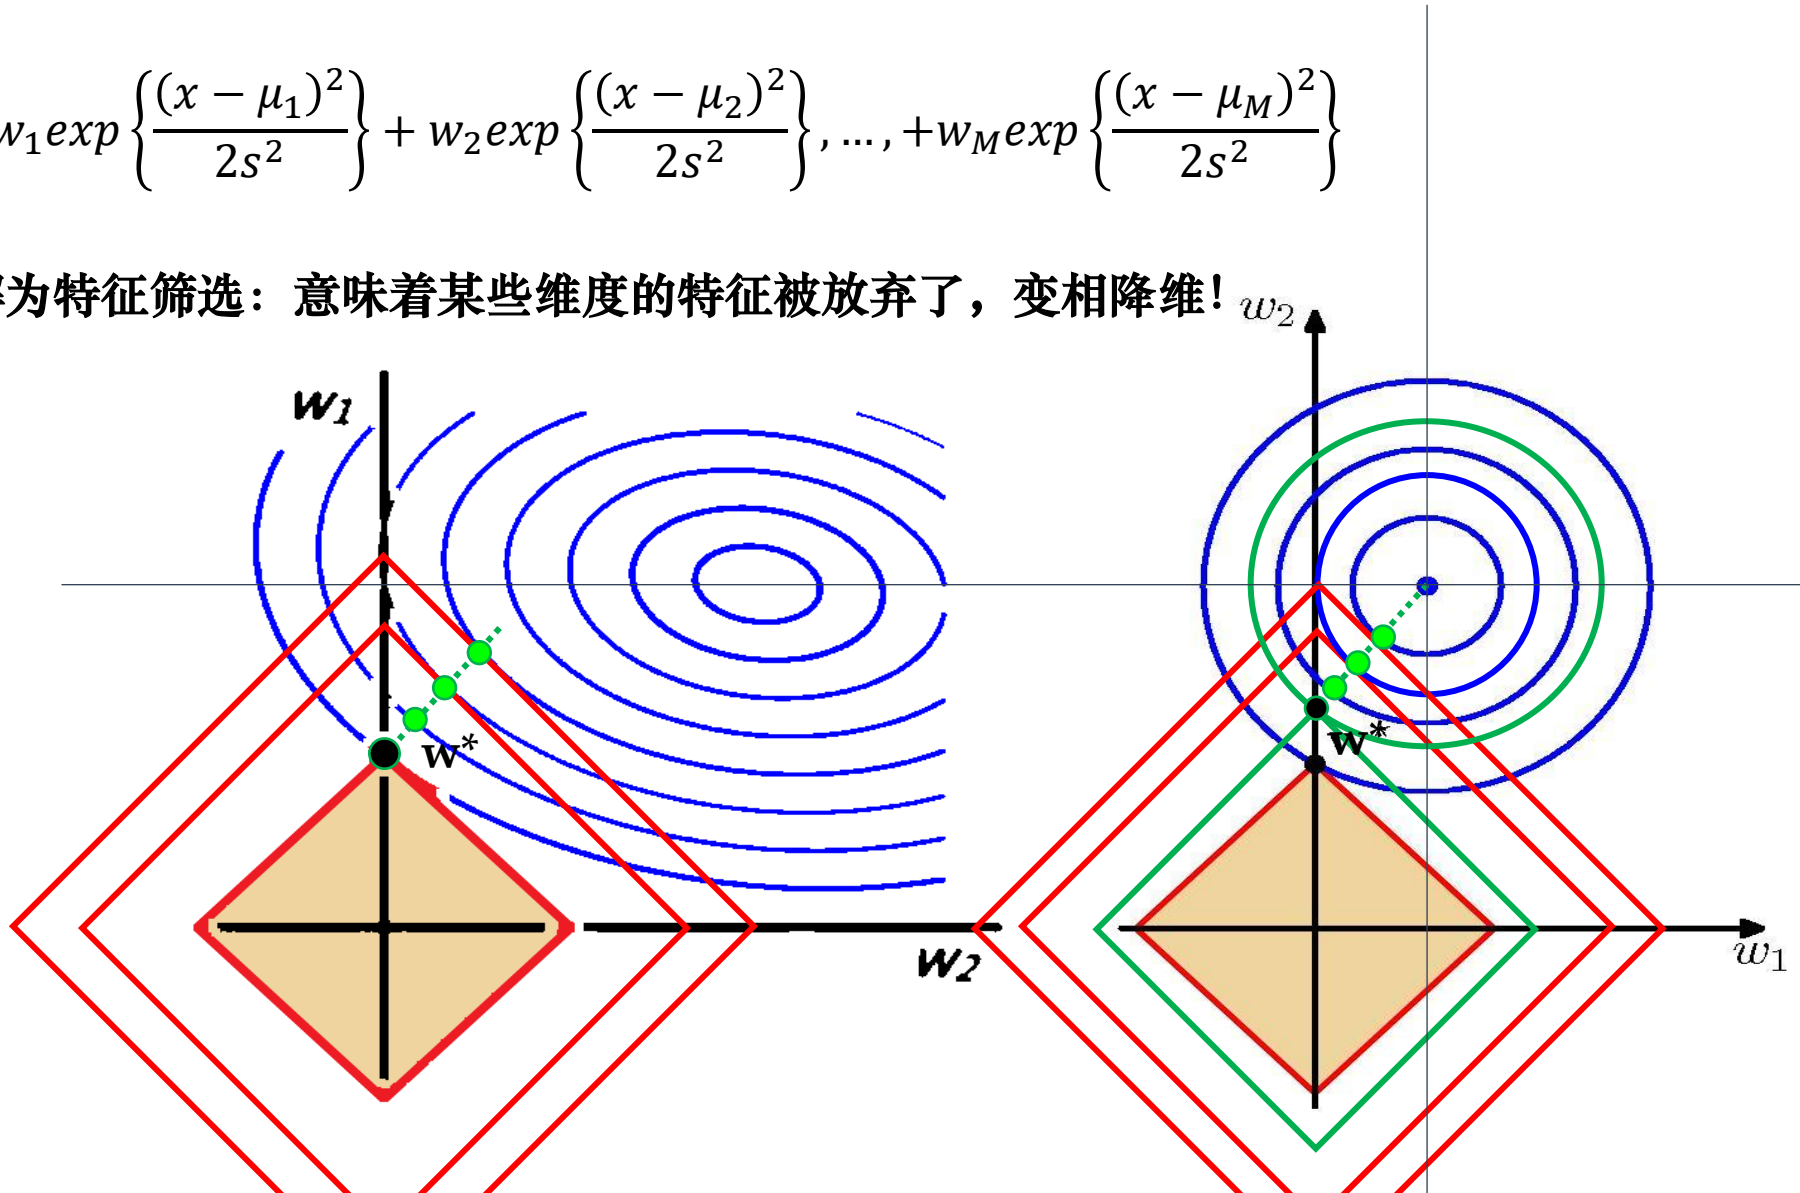
1. 最优解w^*更容易出现在坐标轴上，下图绿色w^*为非坐标轴w^*，黑色为坐标轴上的w^*（某些$w_i = 0$）
   - 有些w^*不是切点，切点在某些情况不存在，空心绿色圆
2. 稀疏解降低了模型复杂度
   - 如M=9，但解中3个$w_i = 0$
   - 则实际的多项式阶数近似为6



四、曲线拟合模型的泛化能力-L1正则化与稀疏解

$$y(x,\mathbf{w}) = w_0 + w_1 exp\left\{\frac{(x-\mu_1)^2}{2s^2}\right\} + w_2 exp\left\{\frac{(x-\mu_2)^2}{2s^2}\right\}, \ldots, + w_M exp\left\{\frac{(x-\mu_M)^2}{2s^2}\right\}$$

稀疏解也可理解为特征筛选：意味着某些维度的特征被放弃了，变相降维！



L1正则化更容易产生稀疏解

- 假定模型只有一维，参数为w，损失函数为Loss(w)，并且 $\left.\frac{dLoss(w)}{dw}\right|_{w=0} = d_0$
- 加入正则化项后损失函数变为：$Loss_{L1}(w) = Loss(w) + \lambda|w|$　　$Loss_{L2}(w) = Loss(w) + \lambda w^2$
- 要查看是否可以获得稀疏解，只需要计算w=0处的导数。

$$\left.\frac{dLoss_{L1}(w)}{dw}\right|_{w=0^-} = d_0 - \lambda$$

$$\left.\frac{dLoss_{L1}(w)}{dw}\right|_{w=0^+} = d_0 + \lambda$$

- 引入L1正则化项后，w=0处导数有突变
- 如果$d_0 - \lambda$和$d_0 + \lambda$异号，则w=0处是极小点，稀疏解。

$$\left.\frac{dLoss_{L2}(w)}{dw}\right|_{w=0^-} = d_0 + 2\lambda w = d_0$$

- 引入L2正则化项后，w=0处导数无变化。

L1正则化更容易产生稀疏解

- 从梯度下降中的权值更新的角度来看

- 正则化项及其梯度：

$$L1 = |w_1| + |w_2| + \cdots + |w_n| \qquad L2 = \frac{1}{2}{w_1}^2 + \frac{1}{2}{w_2}^2 + \cdots + \frac{1}{2}{w_n}^2$$

$$\frac{dL1(w_i)}{dw_i} = sign(w_i) = 1 \; or \; -1 \qquad \frac{dL2(w_i)}{dw_i} = w_i$$

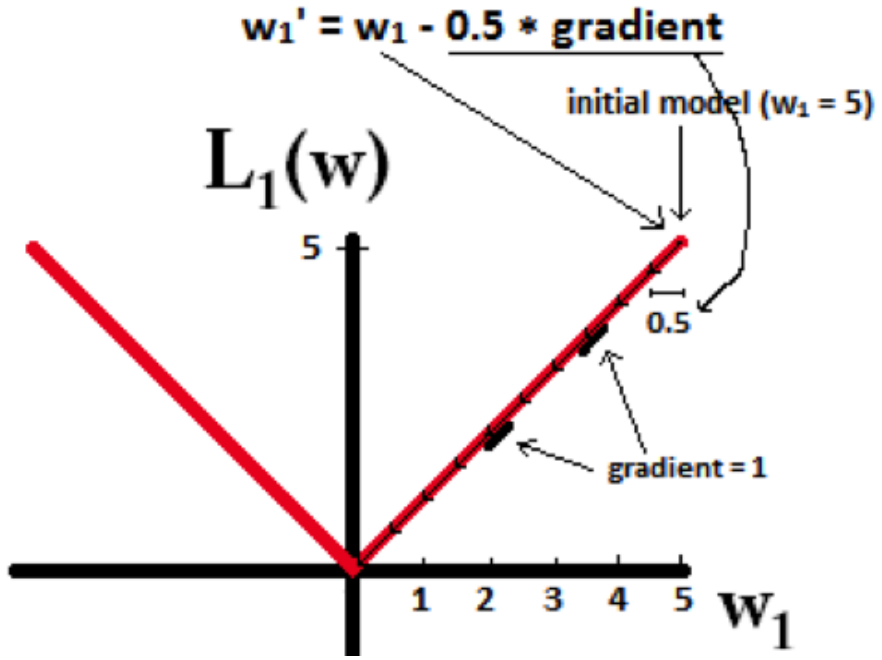
假定w_i当前为某个正的浮点数，学习率为0.5。权值更新情况分别为：

$$L1: \; w_i = w_i - 0.5\frac{dL1(w_i)}{dw_i} = w_i - 0.5 \qquad L2: \; w_i = w_i - 0.5\frac{dL2(w_i)}{dw_i} = w_i - 0.5w_i$$

L1正则化更容易产生稀疏解

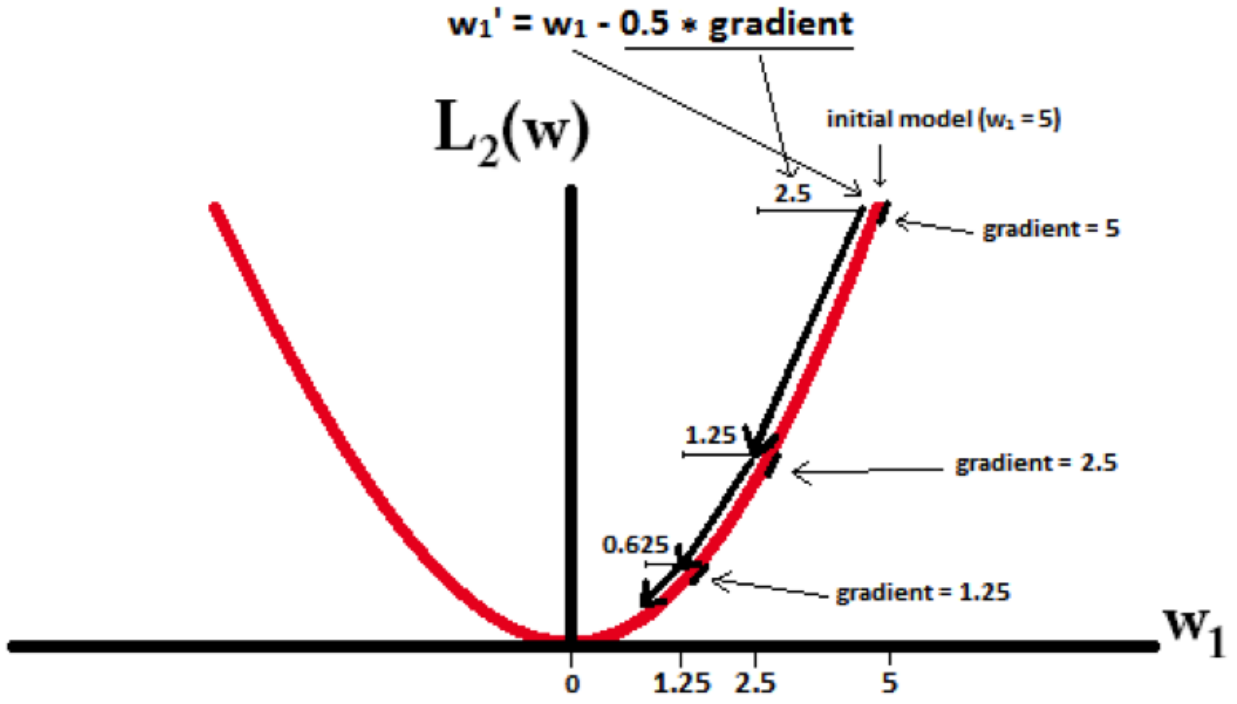
假定wi当前为某个正的浮点数，学习率为0.5。权值更新情况分别为：

L1: $w_i = w_i - 0.5\frac{dL1(w_i)}{dw_i} = w_i - 0.5$　　L2: $w_i = w_i - 0.5\frac{dL2(w_i)}{dw_i} = w_i - 0.5w_i$



如果Loss项的梯度影响不考虑

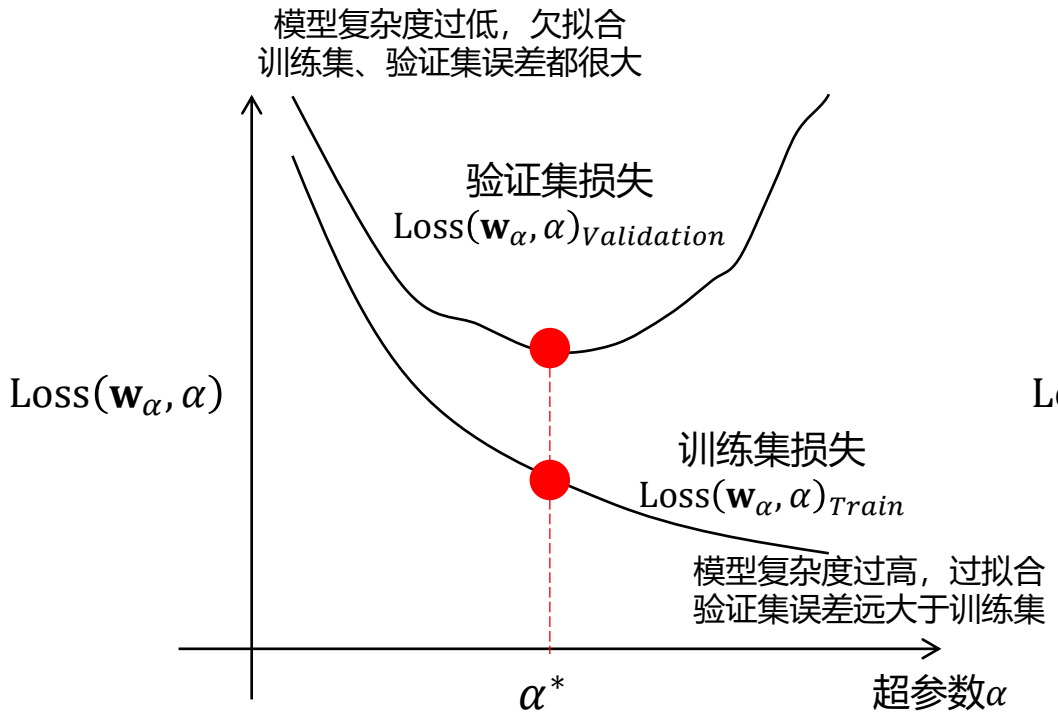
正则化项将w迭代到0，导致稀疏解。

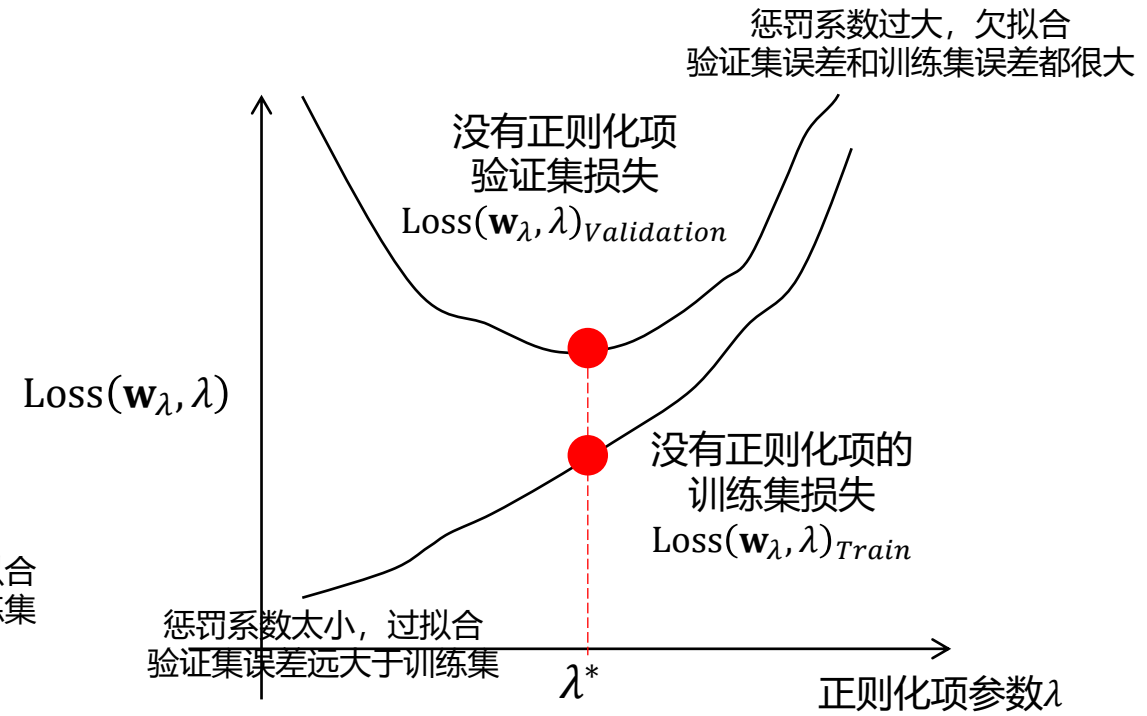


正则化项向0的前进速度越来越慢，无法迭代到0。

四、曲线拟合模型的泛化能力-模型选择

- 训练集：用来学习模型参数$\mathbf{w}$。
- 验证集：用来确定模型超参数，多项式阶数、隐层节点数α、正则化参数λ等。
- 测试集：用来评价神经网络的泛化能力，即在完全没有见过的数据上的性能。

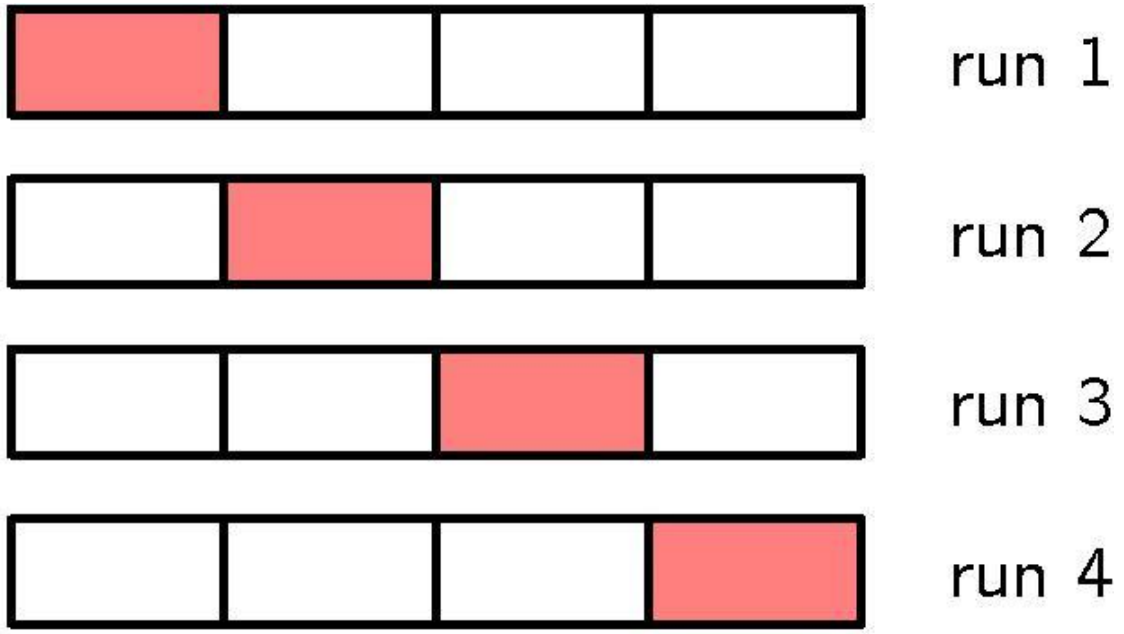




四、曲线拟合模型的泛化能力-交叉验证

其他防止过拟合的策略

- 设置测试集
- 交叉验证
- 集成学习



缺点：

在数据较少的情况下，浪费数据

四、曲线拟合模型的泛化能力-数据的规范化

- 按照特征维度，计算统计均值和标准差
- 中心化
- 尺度归一化
- 保证各维度起到的贡献相同

推荐阅读参考资料

- *Pattern Recognition and Machine Learning*, Chris Bishop, Springer, 2006

亚马逊AWS Director，CMU

SVM主要提出者之一

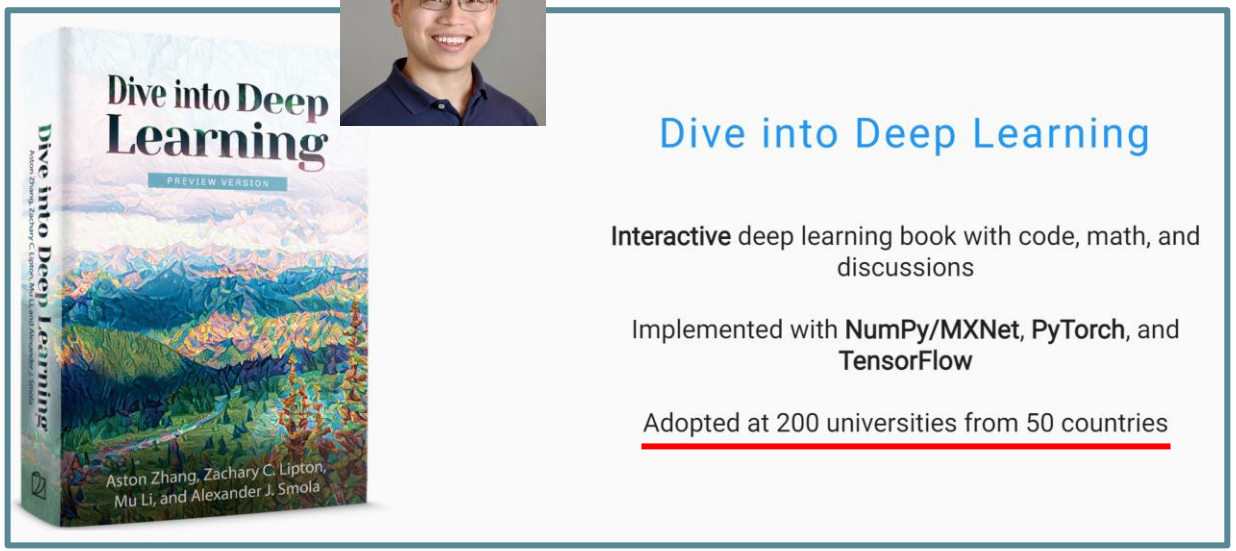


- *Dive into Deep Learning*, Aston Zhang, Zachary C. Lipton, **Mu Li**, and Alexander J. Smola
  - d2l.ai 交互式在线文档，MXNet/PyTorch/TensorFlow
  - BiliBili 有在线公开课

亚马逊AWS Principal Scientist，CMU







作业：

1. 利用Pytorch
2. 自己生产某个曲线的采样数据$\left(x, f_{curve}(x)\right)$
3. 加入加性高斯噪声$Noise \sim N(0, \sigma^2)$，获得样本集$(x, t(x) = f_{curve}(x) + Noise)$
4. 将样本集按照8:2分为训练集和验证集，完成多项式曲线拟合
5. 损失函数采用L2损失，求解方法采用小批梯度下降法
6. 并与直接求解最小二乘方法的解进行对比

感谢！



作业

思考：

1. 正则化的概率意义是什么？
2. 正则化超参数如何设定？

程序设计：在数据量为10,30,100的情况下，完成sin函数拟合

1. 极大似然多项式曲线拟合
2. 带有正则化的极大似然多项式曲线拟合
3. 正则化参数分别取$[-\infty, 1]$中的三个值，近似无惩罚、适度惩罚、过度惩罚

作业与任务

① 作业1：自己生成数据，用Matlab画出数据个数为3，M+1=2情况下的最小二乘几何表达

② 作业2：自己生成数据集，Matlab完成正态分布参数估计。

③ 作业3：上述参数估计是否无偏，证明。如果有偏，给出无偏估计。

④ 作业4：针对cameraman图像，按照天空、草地、其他三个类别，采用正态分布假设，估计三个类别灰度的分布和整个图像的分布，分析直方图与分布的关系，分析似然函数、先验概率分别起到什么作用?

⑤ 任务1：安装Python，numpy，PyTorch（推荐Anaconda方式）， Visdom， Matplotlib

⑥ 任务2：推荐安装：Anaconda、Jupyter notebook 、推荐运行环境Ubuntu20.04/18.04

⑦ 任务3：提前熟悉Python、numpy和Pytorch主要编程指令，熟悉Tensor、ndarray

Temporarily say goodbye to C++ and then Matlab!!

三、最小二乘曲线拟合的总结

思考：

1. 损失函数目前是欧式距离，有没有其他度量方法？
2. x是标量（低维），通过多项式变成向量（高维）。
   - ✓ 不扩展维度是否可以？
   - ✓ 多项式扩展维度的性能怎么样？有没有其他方式？
   - ✓ 采用其他方式扩展维度之后，是否还可以通过损失函数导数=0获得简单线性方程组？
3. 数据量特别大，比如1亿条数据的时候，是否还可以使用导数=0方式求解？
4. 贝叶斯定理中除了似然函数还有先验概率Prior，在曲线拟合这问题中有作用吗？在机器学习中有作用吗？

三、最小二乘曲线拟合的总结

1. 损失函数有没有其他度量方法：有，很多，1范数损失、折页损失等等
2. x是标量（低维），通过多项式变成向量（高维）。
   - ✓ 不扩展维度是否可以：不行，不扩展就只有0阶和1阶变量（直线），用直线拟合曲线显然不合理！
   - ✓ 多项式扩展维度的性能怎么样：不怎么样，没有局部特性，一旦观测训练数据变化，前功尽弃！
   - ✓ 有没有其他方式：有，1）各种局部基函数（如RBF）；2）用数据自适应生成基函数（神经网络）！
   - ✓ 采用其他方式扩展维度之后，是否还可以通过损失函数导数=0获得简单线性方程组：很难！
3. 数据量特别大(N亿条），是否还可用导数=0方式求解：想象物理上无限大的内存，存在吗？
4. 贝叶斯定理中除了似然函数还有先验概率Prior，在曲线拟合这问题中有作用吗？在机器学习中有作用吗？太有用了，正则化。曲线拟合->岭回归；深度学习阶段：BN，earlystop，dropout等。

2、基于Pytorch的曲线拟合实验，MBGD

1. Python
   - numpy（Python的数值计算库）
   - Ndarray (多维数组)
2. Pytorch (Python + Torch + Caffe 2.0)
   - Tensor (Scalar, Vector, Matrix, Tensor)
   - Visdom (Online Visualization)
   - Matplotlib (offline visualization)
3. TensorFlow, MXNet, Caffe 1.0（其他机器学习框架）
4. Jupyter nootbook, Anaconda, pip, Linux （安装、IDE与操作系统）

2、基于Pytorch的曲线拟合实验，MBGD

1. 多项式基函数
2. 训练数据生成
3. 阶数
4. 学习率
5. 收敛速度，是否发散